UNIVERSIDAD EXTERNADO DE COLOMBIA
FACULTAD DE MATEMÁTICAS
PREGRADO EN CIENCIA DE DATOS

Riesgo de Incumplimiento Crediticio

Primera Entrega – Proyecto Integrador

Isabella Pensamiento
Juan Angel Triana

Machine Learning I

Profesora: Juliana De Mier

Bogotá D.C. – Colombia
Agosto de 2026

1 Comprensión y sustentación del artículo

El artículo base es "Optimizing Fintech Marketing: A Comparative Study of Logistic Regression and XGBoost" (Attota & Yarmohammadtoosky, 2024). Los autores trabajan con datos de una fintech de cerca de 988.000 clientes y 541 variables, y construyen tres modelos. El primero identifica a quién enviar una campaña de correo, el segundo predice quién responderá y el tercero, llamado Credit/GoodBad, predice quién podría caer en mora después de recibir una tarjeta.

Antes de entrenar los modelos, los autores realizaron una limpieza de los datos. Identificaron valores que en realidad representaban datos faltantes, eliminaron columnas con demasiados faltantes y también aquellas que tenían el mismo valor para todos los clientes. Los datos faltantes restantes fueron completados usando la mediana o un método basado en clientes similares. Después seleccionaron las variables más útiles, eliminaron aquellas que eran muy parecidas entre sí y balancearon los datos, ya que había muchos más clientes buenos que malos. Finalmente, decidieron no incluir la edad, porque consideraron que no era adecuado evaluar el riesgo de una persona según su edad.

En cuanto a los supuestos, la regresión logística asume una relación relativamente directa entre las variables y la probabilidad de caer en mora, lo que puede ser una limitación cuando las relaciones son más complejas. También se asume que los valores identificados como faltantes realmente lo eran, que el comportamiento de pago pasado puede ayudar a predecir el futuro y que, después de la limpieza, no quedaron variables que aportaran prácticamente la misma información.

Tabla 1: Mejores resultados del artículo para el submodelo Credit (Attota & Yarmohammadtoosky, 2024).

Preprocesamiento	**Modelo**	**Accuracy**	**AUC**
Mediana + binning categórico	Regresión logística	77.19%	85.74%
Mediana + binning categórico	XGBoost	78.18%	86.59%
Bins propios + binning categórico	Regresión logística	77.12%	85.78%
Bins propios + binning categórico	XGBoost	78.10%	86.65%

El artículo también tiene algunas limitaciones. Los datos vienen de una sola empresa y un solo país, por lo que no se puede saber si los resultados serían iguales en otros contextos. Además, los datos están desbalanceados, así que medir solo el porcentaje de aciertos puede ser engañoso. Los autores tampoco analizan si las variables son estadísticamente importantes, ya que su objetivo es predecir, no explicar las causas. Tampoco prueban el modelo con datos de otro periodo o banco para comprobar si mantiene su rendimiento.

Por último, su proceso de limpieza fue pensado para 541 variables, mientras que nuestro dataset tiene solo 13. Por eso, no vamos a replicar esa parte exactamente; es una decisión intencional según las características de nuestros datos.

2 Planteamiento del problema

La pregunta que queremos responder es: **¿qué características de un cliente de crédito de consumo aumentan su probabilidad de caer en mora y cuáles tienen mayor peso?** La analizaremos desde un contexto latinoamericano, usando datos reales de Perú en lugar de los datos originales del artículo.

Es un problema de **clasificación**, donde el modelo debe decidir entre dos opciones. La variable que queremos predecir es `mora`: si vale 1, el cliente tiene historial de mora, equivalente a "bad" en el artículo; si vale 0, está al día, equivalente a "good". Usaremos principalmente regresión logística y la compararemos con otros modelos vistos en clase. XGBoost queda fuera porque no hace parte del curso.

Encontramos una diferencia importante en los datos. En el artículo, los clientes "malos" representan cerca del 37%, mientras que en nuestro dataset los clientes con mora son casi el 70%. Esto no significa que los datos estén mal, pero sí debemos tenerlo en cuenta al evaluar los modelos y confirmar si `mora` representa una situación actual o si indica que el cliente alguna vez se atrasó.

También debemos aclarar que ese 70% no representa la morosidad real del Perú. Según la SBS, esta se encuentra entre 4% y 11%, dependiendo del tipo de entidad. Por lo tanto, nuestro dataset probablemente corresponde a una muestra donde los clientes morosos fueron seleccionados o aparecen en mayor proporción. En otras palabras, el 70% describe esta base de datos y no la situación de todo el sistema financiero peruano.

Las variables disponibles incluyen **días de atraso, score crediticio, nivel de riesgo, experiencia financiera, línea de crédito, deuda, ingresos, ahorros, edad, días trabajados, educación, vivienda y zona del país**. Estas son similares a las utilizadas en el artículo, especialmente las relacionadas con historial de pago, deuda, crédito y características del cliente.

Usar datos de Perú hace que el proyecto sea más relevante para un contexto latinoamericano. La mora y el crecimiento del crédito digital son problemas presentes en diferentes países de la región, por lo que los resultados podrían ser útiles para otras fintech latinoamericanas.

Finalmente, no reproduciremos la comparación con XGBoost ni el proceso de limpieza diseñado para 541 variables, ya que XGBoost no se vio en clase y nuestro dataset solo tiene 13 variables.

3 Estrategia de datos

Vamos a trabajar con un **dataset real**, no con datos simulados.Se llama *BankDefaultAnalysis*, o *Morosidad del Sistema Financiero*, y fue publicado en Kaggle por Calderón Baldeón (2021), con un DOI propio para su citación. Según el contexto presentado por el autor, en julio de 2021 la morosidad del sistema financiero peruano era de 4,04%, llegando a 8,07% en las microfinancieras y 11,25% en las cajas rurales.

Inicialmente pensamos en combinar dos bases de datos y relacionar clientes parecidos para intentar reproducir el modelo "Mail or Don't Mail" del artículo. Sin embargo, descartamos esta opción porque requería hacer demasiadas suposiciones que no podíamos comprobar. Con un solo dataset real, la variable que queremos predecir ya está medida directamente para cada cliente. Además, no necesitamos simular datos, ya que el dataset tiene suficiente tamaño y calidad para realizar el proyecto solicitado en el curso.

Al revisar la calidad de los datos encontramos dos aspectos importantes. Primero, **2,325 filas**, casi el 28% del total, están completamente repetidas, incluso en variables como ingreso y deuda. Por esto, vamos a eliminarlas antes de separar los datos en entrenamiento y prueba, para evitar que un mismo cliente aparezca en ambos grupos. Después de quitar los duplicados, quedan **6,074 clientes distintos**, una cantidad que sigue superando los 5,000 registros que pide la guía del proyecto.

Segundo, encontramos datos faltantes en tres variables: experiencia en el sistema financiero, línea

de crédito y deuda. Estos valores se completarán usando la **mediana**, siguiendo el mismo método utilizado en el artículo.

Tabla 2: Caracterización del dataset (Morosidad del Sistema Financiero, Perú).

Elemento	**Descripción**
Variable objetivo	`mora` (binaria: 1 = con mora, 0 = sin mora), ya presente en el dataset.
Predictores (13)	`atraso`, `score`, `clasif_sbs`, `exp_sf`, `linea_sf`, `deuda_sf`, `ingreso`, `nivel_ahorro`, `edad`, `dias_lab`, `vivienda`, `zona`, `nivel_educ`.
Tamaño	8,399 registros originales.

Por último, revisamos si la variable `mora` tenía sentido comparándola con el score y el ingreso. Encontramos que, a mayor score e ingreso, menor es la probabilidad de mora, lo cual coincide con lo esperado en la realidad. Esto nos da confianza en que la variable está reflejando un comportamiento real y no solo ruido en los datos.

Tabla 3: Cómo traducimos cada objetivo del artículo a una técnica permitida en el curso.

Objetivo del artículo	**Técnica que vamos a usar**
Predecir el riesgo con regresión logística	Regresión logística
Evitar variables que dicen casi lo mismo (ellos usan VIF)	Regularización
Comparar contra un modelo alternativo (ellos usan XGBoost)	Comparación contra LDA y KNN
Mirar más allá del porcentaje de aciertos	Precision, Recall, F1 y AUC, teniendo en cuenta AUC y Recall
Balancear las clases	Se evalúa después de explorar los datos si conviene aplicarlo

Como nuestro dataset tiene 13 variables y no 541, seguiremos la misma idea del artículo, pero de forma más sencilla. Completaremos los datos faltantes solo cuando el análisis exploratorio lo justifique, revisaremos si `linea_sf`, `deuda_sf` e `ingreso` contienen información muy parecida, ya que las tres están relacionadas con el dinero del cliente, y evaluaremos si es necesario ajustar el balance de las clases.

4 Plan de modelamiento y línea base

Vamos a entrenar y comparar cuatro modelos, todos vistos en el curso:

1. **Regresión logística:** Es nuestro modelo principal. Nos permite comparar nuestros resultados con el AUC del artículo, que estuvo entre 85.74% y 85.78%, y además identificar qué variables tienen mayor peso en la predicción.

2. **LDA:** Lo usamos como modelo de comparación. Esperamos que tenga un desempeño menor que la regresión logística, ya que funciona mejor cuando los datos siguen una distribución normal,

algo que puede no cumplirse en variables como el ingreso o la deuda.

3. **KNN:** Este modelo busca clientes similares para hacer la predicción. Lo incluimos para revisar si existen patrones entre clientes parecidos, por ejemplo, según su zona, nivel educativo o score, que los otros modelos no logren identificar.

Dejamos **Naive Bayes** fuera de los modelos principales porque asume que las variables son independientes entre sí, y ya vimos que varias de nuestras variables financieras están relacionadas.

Para evaluar los modelos no podemos depender de una sola métrica. El **AUC-ROC** será nuestra métrica principal, ya que mide qué tan bien distingue el modelo entre clientes morosos y no morosos, sin depender de un punto de corte específico, y además permite comparar nuestros resultados con los del artículo.

Como ya mencionamos, aprobar un crédito a alguien que después no paga es un error más grave que negárselo a alguien que sí habría pagado. Este error ocurre cuando el modelo no detecta a un cliente que realmente está en mora. Por eso, el **Recall de la clase mora=1** será nuestra métrica secundaria. Sin embargo, debemos tener cuidado, porque mora=1 es la clase mayoritaria, con casi el 70% de los casos. Un modelo que siempre prediga "mora=1" tendría un Recall del 100% y una Precision cercana al 70%, aunque no hubiera aprendido nada. Por esto, el Recall siempre se analizará junto con el AUC-ROC. La **Precision y el F1** serán métricas de apoyo, y también revisaremos el Recall de la clase mora=0 para no afectar demasiado a los buenos pagadores.

Para validar los modelos, separaremos los datos en **80% para entrenamiento y 20% para prueba**, manteniendo una proporción similar de clientes con y sin mora en ambos grupos. Dentro del conjunto de entrenamiento usaremos validación cruzada de 5 grupos para elegir los mejores parámetros de cada modelo. El proceso de completar datos faltantes y escalar las variables se realizará únicamente con los datos de entrenamiento, evitando que la información de prueba influya en el modelo. También evaluaremos si es necesario reducir la cantidad de clientes con mora para balancear las clases, ya que en nuestro dataset el desbalance es contrario al del artículo.

Como punto de comparación, utilizaremos una **línea base** que predice que todos los clientes están en mora. Este modelo tiene un AUC de 0.5, es decir, no distingue mejor que una predicción al azar. Aunque tendría un Recall del 100% y una Precision cercana al 70%, esto no significa que haya aprendido algo. Por eso, nuestros modelos deben superar claramente esta línea base en **AUC** y obtener una Precision superior al 70%, sin sacrificar demasiado Recall, para demostrar que realmente logran distinguir entre clientes morosos y no morosos.

Tabla 4: Resumen del plan de modelamiento.

Elemento	**Decisión**
Tarea	Clasificación binaria
Variable objetivo	`mora` (1 = con mora, 0 = sin mora)
Modelos candidatos	Regresión. logística, LDA, KNN
Métrica principal	AUC-ROC
Métricas secundarias	Recall (mora=1), con Precision y F1 de apoyo
Validación	Partición estratificada 80/20 + CV ($k = 5$), sin fuga de datos
Línea base	Clasificador de mayoría (AUC = 0.5)

Referencias

1. Attota, D. C., & Yarmohammadtoosky, S. (2024). *Optimizing Fintech Marketing: A Comparative Study of Logistic Regression and XGBoost*. Kennesaw State University. arXiv:2412.16333.

2. Calderón Baldeón, L. H. (2021). *BankDefaultAnalysis: Morosidad del Sistema Financiero* [Conjunto de datos]. Kaggle. https://doi.org/10.34740/KAGGLE/DSV/2528417

3. Navas-Palencia, G. (2022). *Optimal binning: mathematical programming formulation*. arXiv preprint.

4. Superintendencia Financiera de Colombia. (2026). *Reportes de calidad de cartera e indicadores de morosidad*. https://www.superfinanciera.gov.co

5. Superintendencia de Banca, Seguros y AFP del Perú (SBS). (2021). *Clasificación de riesgo crediticio y estadísticas de morosidad del sistema financiero peruano*. https://www.sbs.gob.pe