Riesgo de Incumplimiento Crediticio
Regresión Logística en el Contexto Latinoamericano

Segunda Entrega — Proyecto Integrador

Isabella Pensamiento Juan Angel Triana

Machine Learning I — Profesora Juliana De Mier
Bogotá D.C., Colombia — Octubre de 2026

1 Ajustes a la primera entrega

Antes de modelar, corregimos seis puntos que nos señaló la profesora. Los resumimos aquí y los desarrollamos en las secciones siguientes.

1. Definimos de forma explícita qué significa `mora` (sección 2).
2. Definimos el momento en que se haría la predicción (sección 2).
3. Revisamos si `atraso`, `clasif_sbs` y `score` pueden filtrar la respuesta (sección 3).
4. Reformulamos la pregunta como una pregunta predictiva (sección 2).
5. Quitamos la regla de "Precision superior al 70%", porque ese número depende de cuántos morosos hay en la muestra y no de la calidad del modelo. Ahora cada modelo se juzga con el AUC, el PR-AUC y con los tipos de error que comete (sección 6).
6. Mejoramos la explicación de los supuestos de la regresión logística (sección 8).

Además, algunas decisiones del plan original cambiaron al revisar los datos y lo visto en clase. La Tabla 1 resume qué cambió y por qué. Mantuvimos la línea base del clasificador de mayoría. Todo el código está en el notebook que acompaña este informe, y todas las cifras salen de ahí.

Table 1: Cambios frente al plan de la primera entrega.

Tema	Primera entrega	Ahora y por qué
Modelos	Regresión logística, Ridge/Lasso, LDA y KNN	Logística, LDA, KNN y Naive Bayes. Ridge/Lasso y QDA quedan para la entrega final
Naive Bayes	Fuera de los principales, por suponer independencia	Sigue sin ser principal; entra solo como contraste
Balanceo	Evaluar si conviene	Cinco opciones probadas; el AUC no mejora, se entrena sin balancear
Imputación	Mediana	Mediana más indicador de faltante
Variables	13 predictores	Escenario principal de 11, sin `atraso` ni `clasif_sbs`
Métricas	AUC y meta de precision	AUC y PR-AUC; sin metas fijas frente a la línea base
Pregunta	Qué características aumentan la probabilidad de mora	Qué tan bien puede predecirse el riesgo de mora

2 Pregunta, definición de `mora` y momento de predicción

Pregunta. Cambiamos la pregunta de la primera entrega por una predictiva: ¿qué tan bien puede predecirse el riesgo de mora de un cliente de crédito de consumo a partir de información financiera y socioeconómica disponible previamente? Primero medimos qué tan bien se predice; después interpretamos variables, sin tratar los coeficientes como causas.

Qué significa `mora`. La descripción del autor habla de pagador al día o cliente moroso, pero no trae diccionario de datos. Comprobamos que `mora` no es lo mismo que tener atraso hoy: el 57,7% de los clientes con `mora = 1` tiene `atraso = 0`, y el 27,2% de los con `mora = 0` sí tiene días de atraso. Por eso usamos esta definición operativa:

> `mora = 1` significa que el cliente aparece marcado como moroso en la base; `mora = 0` que aparece como pagador al día.

Es un supuesto nuestro y lo dejamos como limitación.

Momento de predicción. Pensamos el modelo para cuando el banco evalúa al cliente: conoce perfil, historial y `score`, pero aún no sabe si quedará marcado como moroso. Como la base no trae fechas, esto también es un supuesto que revisamos variable por variable.

3 Revisión de variables y riesgo de fuga

Para cada variable nos preguntamos qué mide, cuándo se observa, si el banco la tendría antes de saber la `mora` y si la mora pudo usarse para construirla. La Tabla 2 resume las decisiones (los momentos son supuestos razonables).

Table 2: Revisión de variables (resumen).

Variable	¿Disponible antes de la mora?	Decisión
Perfil (edad, ingreso, zona, etc.)	Sí	Se usan
`exp_sf`, `linea_sf`, `deuda_sf`	Sí, si son de la fecha de evaluación	Se usan, con esa salvedad
`score`	Normalmente sí; puede actualizarse tras atrasos	Sospechosa leve: se usa y se prueba
`atraso`	Depende del periodo que cubra	Se excluye del escenario principal
`clasif_sbs`	No necesariamente	Se excluye del escenario principal

Criterio principal de exclusión. No sacamos `atraso` y `clasif_sbs` porque "correlacionen poco" con `mora`, sino porque describen comportamiento de pago y podrían medirse después o construirse con información ligada a la mora. Eso es lo que pidió la profesora: revisar el *momento* y la definición, no solo la correlación.

Como complemento, en los datos la correlación de Spearman con `mora` es baja para `atraso` (0,15) y `clasif_sbs` (0,09), y aun en la categoría SBS "pérdida" no todos tienen `mora = 1`. Eso no prueba que sea seguro usarlas; solo indica que no hay una copia exacta de la etiqueta. Por prudencia trabajamos tres escenarios: A (13 variables), B principal (11, sin `atraso` ni `clasif_sbs`) y C conservador (sin `score`).

4 Consolidación de los datos y flujo sin fuga

La base tiene 8 399 registros y 2 325 están completamente repetidos. Las copias casi no tienen faltantes (1,3%), mientras que entre las únicas sí (37,4%). Eliminamos duplicados antes del split y quedan 6 074 clientes. Si no se eliminan, KNN sube el AUC en prueba de forma engañosa (filas idénticas en train y test); la logística casi no cambia.

El VIF va de 1,05 a 1,59 (sin multicolinealidad fuerte), pero hay correlaciones moderadas entre variables financieras (hasta 0,55), relevante para Naive Bayes.

Balanceo. Probamos cinco opciones dentro del pipeline (solo en entrenamiento). La Tabla 3 muestra ROC-AUC y PR-AUC en validación cruzada: casi no cambian. Entrenamos sin balancear; el peso de clases queda como alternativa en la evaluación.

Table 3: Balanceo en CV (regresión logística, escenario B).

Opción	AUC (CV)	PR-AUC (CV)	Recall mora=1	Recall mora=0
Sin balancear	0,698	0,835	0,929	0,236
Peso de clases	0,699	0,836	0,682	0,612
Submuestreo	0,695	0,834	0,671	0,614
Sobremuestreo	0,698	0,836	0,679	0,608
SMOTE	0,695	0,834	0,665	0,616

Flujo. Partición 80/20 estratificada; preprocesamiento dentro de un `Pipeline` (`ImbPipeline` si hay balanceo); semilla 42. Cuatro pruebas en el notebook confirman que no se mezcla train y test ni se filtra la mediana de toda la base; con etiquetas mezcladas el AUC cae a ≈0,49 en los cuatro modelos.

5 Entrenamiento y comparación de modelos

Entrenamos cuatro modelos del curso en el escenario B: regresión logística (principal), LDA (como prometimos en la primera entrega), KNN (k entre 5 y 201 por CV) y Naive Bayes solo como contraste. No replicamos XGBoost ni la limpieza del artículo para 541 variables: eso está fuera del curso y no era el objetivo del proyecto.

La Tabla 4 resume validación cruzada. Logística y LDA quedan prácticamente iguales; KNN cerca; Naive Bayes el peor, coherente con el supuesto de independencia.

Table 4: AUC en validación cruzada (5 folds), escenario B.

Modelo	AUC (media)	Desv.	PR-AUC	Hiperparámetro
Regresión logística	0,698	0,017	0,835	—
LDA	0,699	0,017	0,835	—
KNN	0,689	0,015	0,827	$k = 151$
Naive Bayes	0,657	0,012	0,806	—

6 Validación y resultados

Evaluamos una sola vez el 20% de prueba. El AUC (y el PR-AUC) no dependen del umbral; recall, precision y la matriz de confusión sí. La Tabla 6 resume resultados con umbral 0,5, más la logística con umbral Youden y con peso de clases.

Umbral y Youden (visto en clase). El score es una probabilidad; la etiqueta depende del corte t. El índice de Youden es $J = \text{sensibilidad} + \text{especificidad} - 1 = \text{TPR} - \text{FPR}$. Maximizar J elige un punto de la curva ROC con buen equilibrio entre errores (como en la sesión de selección de modelos). No usamos el conjunto de prueba para elegir t: estimamos probabilidades *out-of-fold* en entrenamiento (`cross_val_predict`) y ahí maximizamos J. El umbral resultante fue $t \approx 0{,}71$. La Tabla 5 muestra cómo cambian sensibilidad, especificidad y J al mover t (misma idea que el ejemplo del curso).

Table 5: Ejemplo de umbrales en OOF (entrenamiento, logística).

Umbral	Sensibilidad	Especificidad	J	FN	FP
0,30	0,994	0,041	0,035	22	1351
0,50	0,929	0,236	0,166	244	1076
0,70	0,703	0,590	0,293	1025	578
0,71	0,684	0,614	0,298	1090	544

Table 6: Resultados en prueba (1 215 clientes).

Modelo	AUC	PR-AUC	Rec. mora=1	Prec. mora=1	Rec. mora=0	FN
Línea base	0,500	0,710	1,000	0,710	0,000	0
Regresión logística	0,722	0,840	0,942	0,754	0,247	50
LDA	0,719	0,838	0,940	0,759	0,267	52
KNN	0,714	0,830	0,961	0,747	0,202	34
Naive Bayes	0,685	0,828	0,641	0,814	0,642	310
Log. (Youden OOF)	0,722	0,840	0,689	0,822	0,634	268
Log. (peso clases)	0,720	0,840	0,683	0,819	0,631	274

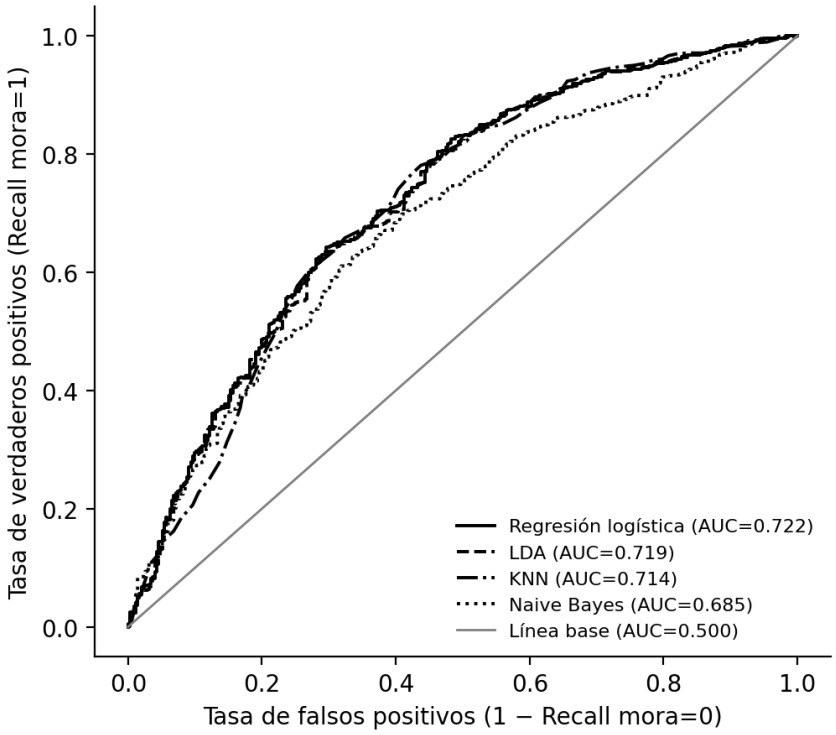


Figure 1: Curvas ROC en el conjunto de prueba.

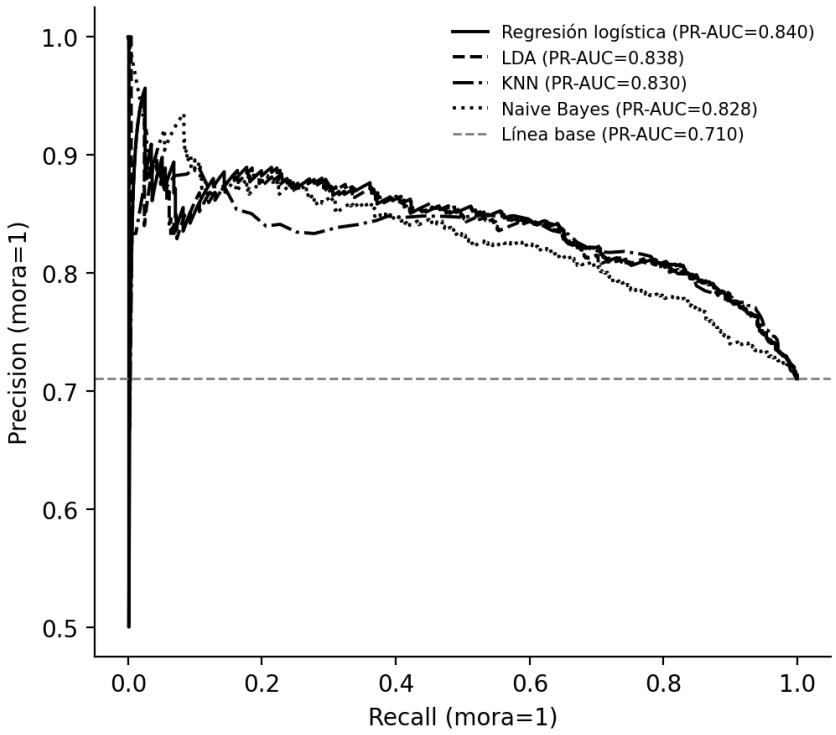


Figure 2: Curvas precision–recall en prueba. La línea horizontal es la prevalencia de mora (≈0,71).

Los tres modelos principales suben el AUC de 0,5 a ≈0,72; Naive Bayes a 0,685. Con umbral 0,5 la logística detecta casi todos los morosos pero rechaza muchos buenos pagadores; con Youden OOF el equilibrio mejora en especificidad, a costa de más FN. Cuál conviene depende del costo de cada error para el banco, y esta base no lo dice.

7 Sensibilidad a las variables sospechosas

Table 7: AUC en prueba por escenario.

Modelo	A completo	B principal	C sin score
Regresión logística	0,734	0,722	0,709
LDA	0,730	0,719	0,707
KNN	0,721	0,714	0,702
Naive Bayes	0,692	0,685	0,677

Incluir `atraso` y `clasif_sbs` sube el AUC unos 0,007–0,012, menos que la variación de la CV. Nos quedamos con el escenario B por ser más seguro.

8 Interpretación preliminar y supuestos

Usamos coeficientes de la logística principal (Figura 3) solo como asociaciones en esta muestra, no como causas. Separamos supuestos del modelo (binaria, independencia de filas, linealidad con el **logit**, VIF bajo), decisiones de preprocesamiento y supuestos sobre calidad de datos (71% de mora no es prevalencia real en Perú).

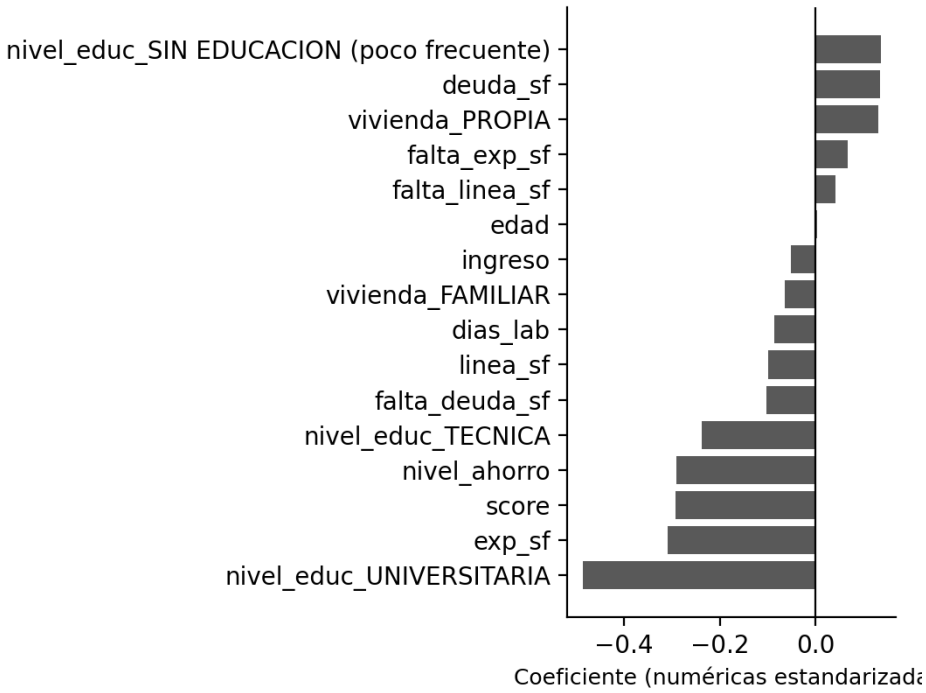


Figure 3: Coeficientes de la regresión logística (sin zonas).

9 Limitaciones, próximos pasos y chequeo de rúbrica

- Sin diccionario: definición de `mora` y momentos son supuestos.
- Probabilidades del modelo ordenan clientes; no son prevalencia poblacional.
- Sin fechas ni ID de cliente: no hay validación temporal.
- Para la entrega final: QDA y regularización (Ridge/Lasso), si el curso lo cubre; comparar costos de error para elegir umbral operativo.

Table 8: Chequeo frente a la rúbrica de la segunda entrega.

Criterio	Evidencia en informe y notebook
Fuga y definición de `mora`	Secciones 2–3; escenarios A/B/C
Pipeline reproducible	Sección 4; semilla 42; sin ajustar con prueba
Balanceo	Tabla 3; ROC-AUC y PR-AUC
Validación y umbral	CV $k = 5$; Youden solo con OOF en train; prueba una vez
Análisis	Tablas 6–7; figuras 1 y 2
Sustentación	Este informe + notebook ejecutable

Declaración de uso de inteligencia artificial

Usamos Claude como apoyo para código, cálculos y borradores; el equipo revisó el planteamiento, las decisiones de diseño y la interpretación. Somos responsables del contenido final.

References

[1] Anthropic. (2026). Claude [Modelo de lenguaje]. https://claude.ai

[2] Attota, D. C., & Yarmohammadtoosky, S. (2024). Optimizing Fintech Marketing (arXiv:2412.16333).

[3] Calderón Baldeón, L. H. (2021). BankDefaultAnalysis. Kaggle.

[4] SBS Perú. Estadísticas de morosidad. https://www.sbs.gob.pe