UNIVERSIDAD EXTERNADO DE COLOMBIA
FACULTAD DE MATEMÁTICAS
PREGRADO EN CIENCIA DE DATOS

Riesgo de Incumplimiento Crediticio

Regresión Logística en el Contexto Latinoamericano

Segunda Entrega – Proyecto Integrador

Isabella Pensamiento
Juan Angel Triana

Machine Learning I

Profesora: Juliana De Mier

Bogotá D.C. – Colombia
Octubre de 2026

1 Ajustes a la primera entrega

Antes de modelar, corregimos seis puntos que nos señaló la profesora. Los resumimos aquí y los desarrollamos en las secciones siguientes.

1. Definimos de forma explícita qué significa `mora` (sección 2).
2. Definimos el momento en que se haría la predicción (sección 2).
3. Revisamos si `atraso`, `clasif_sbs` y `score` pueden filtrar la respuesta (sección 3).
4. Reformulamos la pregunta como una pregunta predictiva (sección 2).
5. Quitamos la regla de "Precision superior al 70%", porque ese número depende de cuántos morosos hay en la muestra y no de la calidad del modelo. Ahora cada modelo se juzga con el AUC y con los tipos de error que comete (sección 6).
6. Mejoramos la explicación de los supuestos de la regresión logística (sección 8).

Mantuvimos la línea base del clasificador de mayoría. Los modelos son solo los que hemos visto en clase hasta hoy: regresión logística, KNN y Naive Bayes. Dejamos fuera LDA/QDA y la regularización con Ridge y Lasso porque aún no los vemos, y los retomaremos cuando se vean. Todo el código está en el notebook que acompaña este informe, y todas las cifras salen de ahí.

2 Pregunta, definición de `mora` y momento de predicción

Pregunta. Cambiamos la pregunta de la primera entrega, que buscaba "qué características aumentan la probabilidad de mora", por una pregunta predictiva: *¿qué tan bien puede predecirse el riesgo de mora de un cliente de crédito de consumo a partir de información financiera y socioeconómica disponible previamente?* Primero medimos qué tan bien se predice y después interpretamos las variables, sin presentar los coeficientes como causas.

Qué significa `mora`. La descripción del autor de la base habla de una "calificación absoluta del cliente" como pagador al día o cliente moroso, pero no trae un diccionario de datos: no dice con qué umbral de días ni en qué periodo se construyó la variable. Lo que sí pudimos comprobar es que `mora` no es lo mismo que tener atraso hoy. El 57.7% de los clientes con `mora = 1` tiene `atraso = 0`, y el 27.2% de los clientes con `mora = 0` tiene días de atraso. Por eso adoptamos esta definición operativa:

> `mora = 1` indica que el cliente aparece marcado como moroso en la base y `mora = 0` que aparece como pagador al día. Es una etiqueta de estado del cliente, no es mora actual ni un conteo de días.

Es un supuesto nuestro y lo declaramos como limitación.

Momento de predicción. Pensamos el modelo para el momento en que el banco evalúa a un cliente de crédito de consumo. En ese momento conoce sus datos personales y socioeconómicos, su historial en el sistema financiero y su score, pero no sabe si quedará marcado como moroso. Una variable solo sirve como predictor si existe antes de conocer esa etiqueta. Como la base no trae fechas, este momento es un supuesto que contrastamos variable por variable en la siguiente sección.

3 Auditoría de variables y riesgo de fuga

Para cada predictor nos preguntamos qué mide, cuándo se observa, si estaría disponible antes de saber la mora y si la mora o algo equivalente pudo usarse para construirlo. La Tabla 1 resume las respuestas. Las columnas sobre el momento de observación son supuestos razonables a partir de la descripción del autor, porque la fuente no lo confirma.

Tabla 1: Auditoría de predictores.

Variable	**Qué mide**	**¿Disponible antes de la mora?**	**Decisión**
edad, nivel_educ, vivienda, zona, dias_lab, ingreso, nivel_ahorro	Perfil personal, laboral y económico	Sí	Se usan
exp_sf, linea_sf, deuda_sf	Experiencia, línea de crédito y deuda en el sistema financiero	Sí, si corresponden a la fecha de evaluación; la fuente no lo garantiza	Se usan, con esa salvedad
score	Calificación crediticia; mayor score, mejor perfil	Normalmente sí, pero un score actualizado tras un atraso ya incluiría la mora	Sospechosa leve: se usa y se prueba sin ella
atraso	Días de atraso histórico	Depende del periodo que cubra	Sospechosa: se excluye del escenario principal
clasif_sbs	Clasificación de riesgo de la SBS (0 normal, 4 pérdida), que se asigna según el comportamiento de pago	No necesariamente	Sospechosa: se excluye del escenario principal

Una relación muy directa con `mora` sería una señal de fuga. No la encontramos: la correlación de Spearman con `mora` es 0.147 para `atraso`, 0.086 para `clasif_sbs` y -0.220 para `score`, y aun entre los clientes clasificados como "pérdida" solo el 79.5% tiene `mora = 1`. Pero que no se vea en los datos no prueba que sea seguro, porque `atraso` y `clasif_sbs` describen por definición el comportamiento de pago. Por prudencia armamos tres escenarios y medimos cuánto cambia el resultado con cada uno:

- **A. Completo:** las 13 variables.
- **B. Principal:** sin `atraso` ni `clasif_sbs`, 11 variables. Es el escenario con el que trabajamos.
- **C. Conservador:** además sin `score`, 10 variables.

4 Consolidación de los datos y flujo sin fuga

Estado de los datos. La base tiene 8,399 registros. De ellos, 2,325 están completamente repetidos. Las filas repetidas casi nunca tienen datos faltantes (1.3%), mientras que entre las únicas sí los tiene el 37.4%, lo que sugiere copias de registros completos y no coincidencias entre clientes. No podemos comprobarlo porque no hay identificador de cliente, así que decidimos eliminarlas antes de dividir. Quedan 6,074 clientes. Para ver qué pasa si no se hace, repetimos la partición con la base original.

En la regresión logística el AUC casi no cambió (0.710 con duplicados y 0.715 sin ellos), pero en KNN pasó de 0.652 a 0.732, porque cerca del 42% de las filas de prueba tenía una copia exacta en entrenamiento. Es una fuga silenciosa que se evita eliminando duplicados primero.

La Tabla 2 resume el estado final. Las variables de dinero no repiten la misma información, que era una duda de la primera entrega: los VIF van de 1.05 a 1.59 y la mayor correlación entre dos variables es 0.55.

Tabla 2: Estado de los datos.

Elemento	**Valor**
Registros originales / únicos	8,399 / 6,074
Proporción de mora (únicos)	71.0%
Entrenamiento / prueba (80/20)	4,859 / 1,215
Faltantes: exp_sf, linea_sf, deuda_sf	29.7%, 18.3%, 7.4%
VIF máximo / correlación máxima	1.59 / 0.55

Decisión sobre imputar. Sí se imputa, con la mediana, como en el artículo, porque eliminar filas con faltantes nos haría perder más del 37% de los clientes. Además agregamos una columna que marca qué datos faltaban, porque faltar no es aleatorio: entre los clientes sin `exp_sf` la mora es del 79.7% y entre los que sí la reportan es del 67.3%.

Decisión sobre balancear. En nuestra base los morosos son mayoría, al contrario del artículo. Probamos con la regresión logística las estrategias vistas en clase: sin balancear, peso de clases, submuestreo, sobremuestreo y SMOTE. Todas se aplican dentro del pipeline y solo con los datos de entrenamiento de cada grupo de la validación cruzada. La Tabla 3 muestra que el AUC es el mismo en las cinco, lo que tiene sentido porque balancear no cambia qué tan bien se ordenan los clientes, solo mueve el punto de corte efectivo. Cambia el equilibrio entre errores: sin balancear se reconoce al 23.6% de los buenos pagadores, y con cualquier técnica a cerca del 61%, a cambio de detectar menos morosos. Como el AUC no mejora, el modelo principal se entrena sin balancear y mostramos el peso de clases como alternativa.

Tabla 3: Opciones de balanceo en validación cruzada (regresión logística, entrenamiento).

Opción	**AUC**	**Recall (mora=1)**	**Recall (mora=0)**
Sin balancear	0.698	0.929	0.236
Peso de clases	0.699	0.682	0.612
Submuestreo	0.695	0.671	0.614
Sobremuestreo	0.698	0.679	0.608
SMOTE	0.695	0.665	0.616

Flujo. Todo el preprocesamiento va dentro de un `Pipeline`, en este orden: primero se separa entrenamiento y prueba con estratificación, y después, dentro de cada partición de la validación cruzada, se imputa con la mediana, se estandariza, se codifican las categorías con one-hot, se balancea si corresponde y se entrena el modelo. Así la mediana, la media y la desviación estándar se calculan solo con los datos de entrenamiento de cada partición, y la información de prueba nunca influye en el modelo. La semilla está fija (42).

Pruebas de que no hay fuga. No nos quedamos con afirmar que el flujo es correcto; lo compro-

bamos en el notebook con cuatro pruebas. Primera, ninguna fila está a la vez en entrenamiento y en prueba. Segunda, la proporción de morosos es 71.0% en el entrenamiento, en la prueba y en cada uno de los 5 grupos de la validación cruzada, es decir, la partición está estratificada. Tercera, la mediana que usa el imputador es la del entrenamiento y no la de toda la base. Cuarta, si mezclamos al azar las etiquetas de entrenamiento, el AUC cae a 0.493 en los tres modelos, como debe ser: el flujo no filtra la respuesta. Estas pruebas muestran que el flujo no filtra información de la prueba. Que una variable como `score` ya incorpore la mora es otro riesgo, y lo tratamos con la auditoría de la sección 3 y el análisis de la sección 7.

5 Entrenamiento y comparación de modelos

Entrenamos tres modelos vistos en clase en el escenario B. La regresión logística es el modelo principal y no tiene hiperparámetros, porque no usamos penalización. KNN compara contra un modelo que busca clientes parecidos, y elegimos su número de vecinos k entre 5 y 201 con validación cruzada estratificada de 5 grupos y AUC como criterio. Naive Bayes gaussiano compara contra un modelo probabilístico simple. En la primera entrega lo habíamos dejado fuera por su supuesto de independencia, pero ahora que lo vimos lo incluimos, porque nuestras variables tienen poca relación entre sí (sección 4). La Tabla 4 muestra el AUC en validación cruzada con su variabilidad.

Tabla 4: AUC en validación cruzada (5 grupos), escenario B.

Modelo	**AUC (media)**	**Desv. est.**	**Hiperparámetro**
Regresión logística	0.698	0.017	—
KNN	0.689	0.015	$k = 151$
Naive Bayes	0.657	0.012	—

La regresión logística y KNN quedan casi empatados: la diferencia es del tamaño de la desviación estándar. El mejor k de KNN es grande, lo que indica que necesita promediar muchos vecinos para no seguir el ruido, y un modelo más flexible no ayuda con estas variables. Naive Bayes es el peor, y es razonable porque su supuesto de independencia no se cumple del todo.

6 Validación y resultados

Con los modelos ya elegidos, evaluamos una sola vez en el 20% de prueba. El AUC es la métrica principal porque no depende del punto de corte ni de cuántos morosos hay. Recall, Precision, F1 y la matriz de confusión son complementos, con punto de corte 0.5. No juzgamos ningún modelo con una cifra fija: preguntamos cuánto mejora frente a la línea base y qué errores comete. La Tabla 5 muestra los resultados y la Figura 1 las curvas ROC. VP, FN, FP y VN son los aciertos y errores de la matriz de confusión.

Mejora frente a la línea base. La regresión logística y KNN suben el AUC de 0.5 a cerca de 0.72, y Naive Bayes a 0.685. Los intervalos del 95% por remuestreo en prueba van, por ejemplo, de 0.689 a 0.751 para la regresión logística y de 0.680 a 0.747 para KNN, así que no podemos separar a estos dos modelos. La mejora es real pero moderada: el nivel está lejos del 85.7% que reporta el artículo. Las diferencias pueden venir de que nuestra base tiene 13 variables y no 541, unos 6 mil clientes y no 988 mil, y otra definición de mora, pero no lo comprobamos.

Qué errores comete. Con punto de corte 0.5, la regresión logística detecta al 94.2% de los morosos,

Tabla 5: Resultados en el conjunto de prueba (1,215 clientes: 863 con mora y 352 sin mora).

Modelo	**AUC**	**Recall (mora=1)**	**Precision (mora=1)**	**Recall (mora=0)**	**FN**	**FP**
Línea base (siempre mora=1)	0.500	1.000	0.710	0.000	0	352
Regresión logística	0.722	0.942	0.754	0.247	50	265
KNN	0.714	0.961	0.747	0.202	34	281
Naive Bayes	0.685	0.641	0.814	0.642	310	126
Reg. logística con peso de clases	0.720	0.683	0.819	0.631	274	130

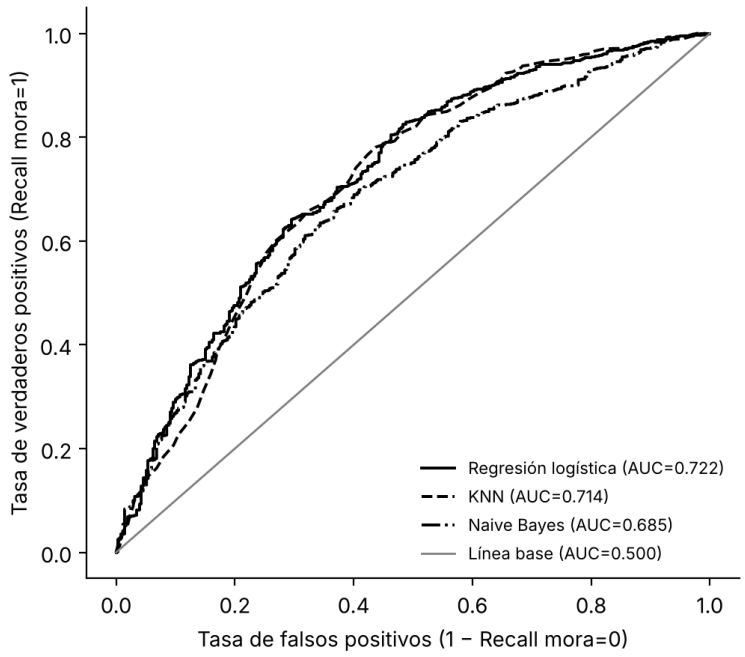


Figura 1: Curvas ROC en el conjunto de prueba.

solo se le escapan 50, pero reconoce únicamente al 24.7% de los buenos pagadores, es decir, rechaza a 265 de 352. La línea base detecta a todos los morosos y rechaza a todos los buenos pagadores. La exactitud sube de 71.0% a 74.1%, una mejora pequeña. A este punto de corte el modelo se parece mucho a la estrategia trivial, y su ganancia está sobre todo en el ordenamiento que mide el AUC. Con peso de clases pasa lo contrario: reconoce al 63.1% de los buenos pagadores, pero deja escapar 274 morosos. Naive Bayes cae en un punto intermedio, pero con peor AUC. Qué punto es mejor depende de cuánto le cuesta al banco cada error, y esta base no lo permite saber.

7 Sensibilidad a las variables sospechosas

Repetimos todo el procedimiento con los tres escenarios. La Tabla 6 muestra el AUC de prueba.

Incluir `atraso` y `clasif_sbs` sube el AUC entre 0.007 y 0.012, un cambio menor que la variabilidad de la validación cruzada. Esto indica que esas variables no "saben" la respuesta, y que excluirlas casi no cuesta capacidad predictiva, así que mantenemos el escenario B como más seguro. Quitar además el `score` baja entre 0.008 y 0.013, y el resultado se mantiene claramente por encima de 0.5.

Tabla 6: AUC en prueba según el escenario de variables.

Modelo	A. Completo	B. Principal	C. Conservador
Regresión logística	0.734	0.722	0.709
KNN	0.721	0.714	0.702
Naive Bayes	0.692	0.685	0.677

8 Interpretación preliminar y supuestos

Qué variables pesan más. Usamos los coeficientes de la regresión logística principal. Las variables numéricas están estandarizadas, y en las categóricas la comparación es contra una categoría de referencia (`nivel_educ` contra secundaria y `vivienda` contra alquilada). La Figura 2 muestra los coeficientes y las razones de odds salen de ahí. Las asociaciones más fuertes con menor mora son tener educación universitaria (razón de odds 0.62 frente a secundaria), más experiencia en el sistema financiero (`exp_sf`, 0.73 por desviación estándar), mayor `score` (0.75) y mayor nivel de ahorro (0.75). Mayor `deuda_sf` se asocia con más mora (1.14). El ingreso y la edad pesan muy poco una vez se tienen en cuenta las demás variables.

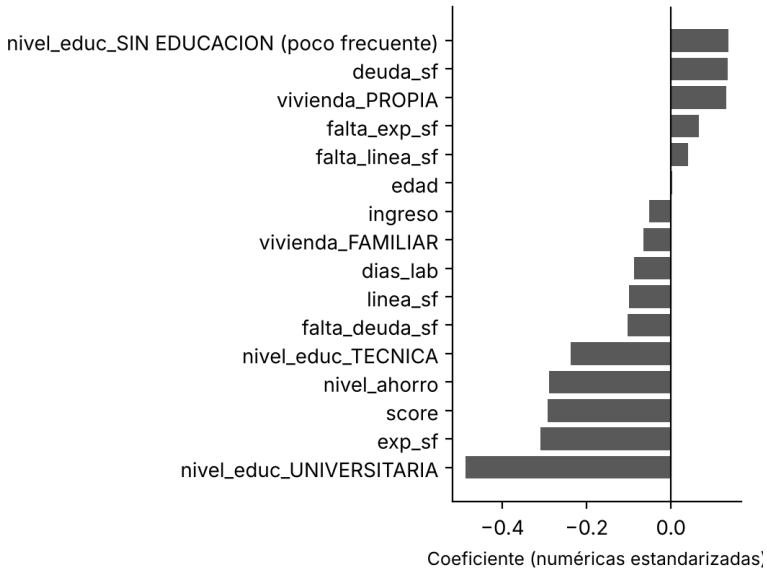


Figura 2: Coeficientes de la regresión logística (numéricas estandarizadas, sin zonas).

Estos coeficientes describen asociaciones en esta base y no efectos causales. Por ejemplo, que la educación universitaria aparezca ligada a menos mora no quiere decir que estudiar reduzca la mora, porque educación, ingreso y empleo suelen ir juntos. Además, la categoría de referencia (secundaria) tiene solo 223 clientes, y `SIN EDUCACION` solo 29, así que esas comparaciones son poco estables.

Supuestos de la regresión logística. Los separamos en tres tipos, porque en la primera entrega los mezclamos.

- **Supuestos del modelo.** La variable a predecir es binaria. Las observaciones son independientes, y por eso eliminamos las copias exactas. Cada variable numérica tiene una relación lineal con el logit, el logaritmo de la razón entre la probabilidad de mora y la de no mora, y no con

la probabilidad directamente. No lo verificamos variable por variable; una pista indirecta es que KNN, que no supone linealidad, no mejora a los modelos lineales. Tampoco debe haber multicolinealidad fuerte, y los VIF lo confirman. Naive Bayes, además, supone variables independientes entre sí. Además se necesitan suficientes datos de cada clase.

- **Decisiones de preprocesamiento.** No son supuestos del modelo, son elecciones nuestras: imputar con la mediana y marcar los faltantes, estandarizar, codificar con one-hot, eliminar duplicados y excluir `atraso` y `clasif_sbs`.
- **Supuestos sobre la calidad de los datos.** El modelo no puede comprobarlos. Suponemos que `mora` está bien medida y significa lo mismo para todos, que los faltantes son datos realmente desconocidos, y que las variables se midieron antes de conocer la mora. También suponemos que la muestra se parece a la población que nos interesa, y esto no se cumple del todo: la base tiene 71% de morosos y la morosidad real en Perú está entre 4% y 11% según la SBS.

9 Limitaciones y próximos pasos

- La definición de `mora` y el momento de medición de cada variable son supuestos, porque la base no tiene diccionario. Seguiremos buscando documentación del autor.
- Como la muestra tiene 71% de morosos, las probabilidades del modelo no son probabilidades reales de mora en la población. Sirven para ordenar clientes y no para medir cuánto riesgo hay en el sistema.
- No hay fechas ni identificador de cliente: no pudimos validar con otro periodo ni comprobar que los duplicados sean el mismo cliente.
- Para la entrega final queremos comparar puntos de corte y decidir el modelo definitivo, priorizando interpretabilidad. Cuando veamos regularización y LDA/QDA evaluaremos si aportan algo.

Declaración de uso de inteligencia artificial

Usamos Claude como apoyo para revisar la redacción, organizar el código del notebook y verificar cálculos (Anthropic, 2026). Las decisiones de diseño y la revisión de los resultados son del equipo.

Referencias

1. Anthropic. (2026). Claude (Sonnet 5) [Modelo de lenguaje de gran escala]. https://claude.ai
2. Attota, D. C., & Yarmohammadtoosky, S. (2024). Optimizing Fintech Marketing: A Comparative Study of Logistic Regression and XGBoost. Kennesaw State University. arXiv:2412.16333.
3. Calderón Baldeón, L. H. (2021). BankDefaultAnalysis: Morosidad del Sistema Financiero [Conjunto de datos]. Kaggle. https://doi.org/10.34740/KAGGLE/DSV/2528417
4. Superintendencia de Banca, Seguros y AFP del Perú (SBS). (2021). Clasificación de riesgo crediticio y estadísticas de morosidad del sistema financiero peruano. https://www.sbs.gob.pe