UNIVERSIDAD EXTERNADO DE COLOMBIA

FACULTAD DE MATEMÁTICAS

PREGRADO EN CIENCIA DE DATOS

Riesgo de Incumplimiento Crediticio

Regresión Logística en el Contexto Latinoamericano

Entrega Final (Proyecto Integrador)

Fase 3: consolidación, despliegue y comunicación

Isabella Pensamiento

Juan Angel Triana

Machine Learning I

Profesora: Juliana De Mier

Bogotá D.C. – Colombia

Noviembre de 2026

1 Decisión de negocio y alcance

Pregunta del comité. ¿Podemos usar la información disponible de un solicitante para priorizar clientes según riesgo relativo sin rechazar de más a buenos pagadores? Para decidir rechazos, el umbral pesa tanto como el AUC.

Pregunta técnica (heredada de la 2.ª entrega). ¿Qué tan bien puede predecirse el riesgo de mora a partir de información financiera y socioeconómica disponible *previamente*?

En esta entrega cerramos con un solo modelo (regresión logística, escenario B), con sus límites claros y cortes elegidos según el costo de equivocarse. No volvemos a competir QDA, Ridge ni Lasso en la misma prueba.

2 Limitaciones que condicionan cualquier lectura

- **Temporalidad.** Sin fechas ni diccionario no demostramos que la etiqueta `mora` sea un evento futuro. Aprendemos a separar clientes ya marcados como morosos o pagadores al día con variables que *suponemos* disponibles antes.
- **Prevalencia.** En la muestra hay ≈71% de mora. No es representativa del Perú (4% a 11% según la SBS). Los valores de `predict_proba` sirven para **ordenar** riesgo en una población similar a esta base, no como probabilidad real de mora en el mercado.
- **Identidad y duplicados.** No hay ID de cliente. Eliminamos duplicados exactos de forma conservadora, pero no sabemos si son la misma persona.
- `score`**.** Lo mantenemos en el escenario principal y probamos el escenario C sin él. Si el score se actualizara después de atrasos, habría fuga residual no verificable sin metadatos.
- **Conjunto de prueba.** Ya lo usamos en la 2.ª entrega para comparar modelos, escenarios y reportes con distintos cortes. En esta fase no lo usamos para elegir modelo ni cortes. Solo repetimos cifras de cierre y aplicamos umbrales fijados con predicciones fuera del fold (OOF) en entrenamiento.

Sobreajuste. Usamos logística sin balanceo y modelo **congelado**; la selección se apoyó en CV y los umbrales solo en OOF. El conjunto de prueba en Fase 3 es **solo lectura**. AUC en prueba ≈0,72 está alineado con CV ≈0,70, pero no garantiza generalización fuera de esta base.

3 Datos, fuga de información y escenario B

Usamos *BankDefaultAnalysis* (Kaggle, Calderón Baldeón, 2021): 8,399 registros, 13 predictores más `mora`. Tras quitar 2,325 filas duplicadas quedan 6,074 clientes. Partición 80/20 estratificada, semilla 42 (4,859 entrenamiento, 1,215 prueba).

Definición operativa: `mora = 1` es cliente marcado moroso en la base, `mora = 0` pagador al día. No afirmamos mora en un periodo exacto.

Excluimos `atraso` y `clasif_sbs` del escenario principal porque describen comportamiento de pago y no podemos asegurar que se observen antes de la etiqueta. Escenario **B** (11 variables) es el modelo final. Escenarios A (13 variables) y C (sin `score`) se usaron en la 2.ª entrega como sensibilidad.

4 Flujo de preprocesamiento y balanceo

El preprocesamiento va en `Pipeline` (o `ImbPipeline` si hubiera balanceo): imputación mediana con indicador, estandarización, one-hot (`drop='first'`, `min_frequency=50`), modelo. En validación cruzada cada fold ajusta transformaciones solo con su entrenamiento.

Probamos cinco estrategias de balanceo solo en entrenamiento (Tabla 1). Aquí el balanceo casi no cambió el AUC. Entrenamos el modelo final sin balancear. Lo que cambió fue cuántos morosos y buenos pagadores detecta cada opción.

Tabla 1: Balanceo en validación cruzada (regresión logística, escenario B), 2.ª entrega.

Opción	**AUC (CV)**	**PR-AUC (CV)**	**Rec. mora=1**	**Rec. mora=0**
Sin balancear	0,698	0,835	0,929	0,236
Peso de clases	0,699	0,836	0,682	0,612
Submuestreo	0,695	0,834	0,671	0,614
Sobremuestreo	0,698	0,836	0,679	0,608
SMOTE	0,695	0,834	0,665	0,616

5 Modelo final y contraste con el artículo

5.1 Configuración definitiva

Tabla 2: Modelo final congelado (decisiones documentadas del equipo en Fase 3).

Elemento	**Valor**
Algoritmo	Regresión logística (`C=1e6`, `max_iter=5000`)
Variables	11 (escenario B): perfil, `exp_sf`, `linea_sf`, `deuda_sf`, `score`; sin `atraso` ni `clasif_sbs`
Balanceo	Ninguno
Semilla	42
Salida operativa	Score de riesgo relativo (`predict_proba[:,1]`)
Artefacto	`pipeline_logistica_B.joblib`

5.2 Por qué logística y no LDA, KNN o Naive Bayes

La Tabla 3 (2.ª entrega) muestra AUC en CV: logística 0,698 $\pm$ 0,017, LDA 0,699, KNN 0,689 ($k = 151$), Naive Bayes 0,657. Los tres primeros quedan casi empatados. Naive Bayes queda peor, coherente con correlaciones entre variables financieras. Elegimos la logística porque se puede explicar y porque es el modelo del artículo (*Credit/GoodBad*).

5.3 Reproducción de objetivos del artículo

- **Reproducimos la idea general:** clasificación binaria de riesgo, métrica AUC, limpieza básica y logística como modelo interpretable en contexto latinoamericano (Perú).
- **No reproducimos:** XGBoost, selección masiva de 541 variables, pipeline del paper a otra escala y país.
- **Brecha de desempeño.** AUC en prueba $\approx$0,72 frente a objetivos más altos en el artículo. **Posibles razones no comprobadas:** muestra con 71% de mora, escenario B sin variables

de pago posteriores, ausencia de diccionario y calidad distinta a la del paper. Discriminación moderada (mejor que azar, lejos de separación perfecta). Un AUC de 0,72 **no** significa 72% de aciertos.

6 Validación cruzada (selección)

Tabla 3: AUC en validación cruzada (5 folds), escenario B. Fuente: 2.ª entrega (mismas partición y semilla).

Modelo	AUC (media)	Desv.	PR-AUC	Hiperparámetro
Regresión logística	0,698	0,017	0,835	—
LDA	0,699	0,017	0,835	—
KNN	0,689	0,015	0,827	$k = 151$
Naive Bayes	0,657	0,012	0,806	—

Tabla 4: AUC en CV (solo logística) por escenario de variables. Fase 3.

Escenario	AUC CV
A. Completo (13)	0,715
B. Principal (11)	0,698
C. Conservador (sin `score`)	0,692

7 Evaluación en prueba (cierre congelado)

En la 2.ª entrega consultamos el conjunto de prueba varias veces (modelos, escenarios y reportes con distintos cortes). Eso ya está documentado. En la Fase 3 no volvemos a usar la prueba para elegir modelo ni umbral. Aquí repetimos las cifras de cierre congelado y verificamos que reentrenar el mismo pipeline reproduce AUC ≈0,722 (cuaderno de Fase 3 entregado con el proyecto).

Tabla 5: Resultados en prueba (1,215 clientes), 2.ª entrega.

Modelo	AUC	PR-AUC	Rec. mora=1	Prec. mora=1	Rec. mora=0	FN
Línea base	0,500	0,710	1,000	0,710	0,000	0
Regresión logística	0,722	0,840	0,942	0,754	0,247	50
LDA	0,719	0,838	0,940	0,759	0,267	52
KNN	0,714	0,830	0,961	0,747	0,202	34
Naive Bayes	0,685	0,828	0,641	0,814	0,642	310
Log. (Youden OOF)	0,722	0,840	0,689	0,822	0,634	268

Las curvas de la Figura 1 resumen discriminación sin fijar umbral (cierre 2.ª entrega). Con prevalencia ≈71% la PR-AUC alta refleja en parte la clase mayoritaria; el comité debe leer sensibilidad y falsos positivos al elegir corte.

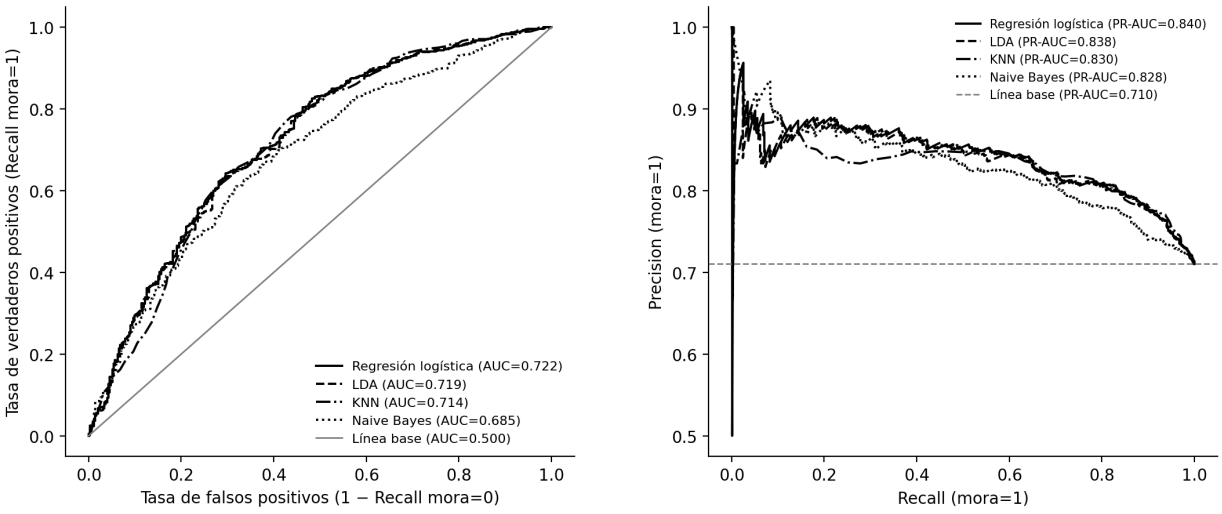


Figura 1: ROC y precision–recall en prueba (regresión logística y comparadores, 2.ª entrega).

8 Umbrales: Youden y escenarios de costo (OOF)

La etiqueta binaria depende del umbral t sobre el score del modelo. El índice de Youden $J = \text{TPR} - \text{FPR}$ se maximizó con probabilidades OOF en entrenamiento (cada cliente recibe el score de un fold donde no entró al ajuste; $t \approx 0{,}71$).

Para la entrega final añadimos costos simbólicos $C = r \cdot FN + FP$ con $r = \text{costo(FN)}/\text{costo(FP)}$. Minimizamos C en OOF (4,859 clientes de entrenamiento), sin mirar la prueba. Incluimos $r \in \{1, 2, 5\}$ y la línea base que predice siempre mora (FN$=0$, FP$=$ buenos pagadores en OOF $= 1{,}409$).

Tabla 6: Umbrales y costo simbólico en OOF (entrenamiento, logística B). $C = r \cdot FN + FP$.

Criterio	t	**FN**	**FP**	C (r=1)	C (r=2)	C (r=5)	**Esp.**
Línea base (siempre mora)	—	0	1409	1409	1409	1409	0,000
Convención	0,50	244	1076	1320	1564	2296	0,236
Costo $r = 1$ (mín. en OOF)	0,57	381	921	1302	1683	2826	0,346
Youden OOF	0,71	1090	544	1634	2724	5994	0,614
Costo $r = 2$ (mín. en OOF)	0,27	13	1366	1379	1392	1431	0,031
Costo $r = 5$ (mín. en OOF)	0,14	0	1404	1404	1404	1404	0,004

La línea base fija $C = 1409$ para cualquier r porque FN$= 0$. Con $r = 1$ el costo baja a 1302 (reducción ≈7,6% frente a 1409): en ese escenario el corte binario sí mejora rechazar a todos. Con $r = 2$ el mínimo (1392) apenas baja la línea base; con $r = 5$ el óptimo (1404) casi coincide con 1409. Youden sube el costo simbólico (1634 / 2724 / 5994 según r) pero reconoce más buenos pagadores a cambio de más morosos etiquetados como riesgo bajo. Para el comité: si un moroso cuesta el doble o más que un falso rechazo, el corte que minimiza C en OOF casi no gana a predecir mora para todos; cuando ambos errores pesan parecido ($r = 1$) sí hay margen, y el score sigue siendo útil para ordenar la cartera.

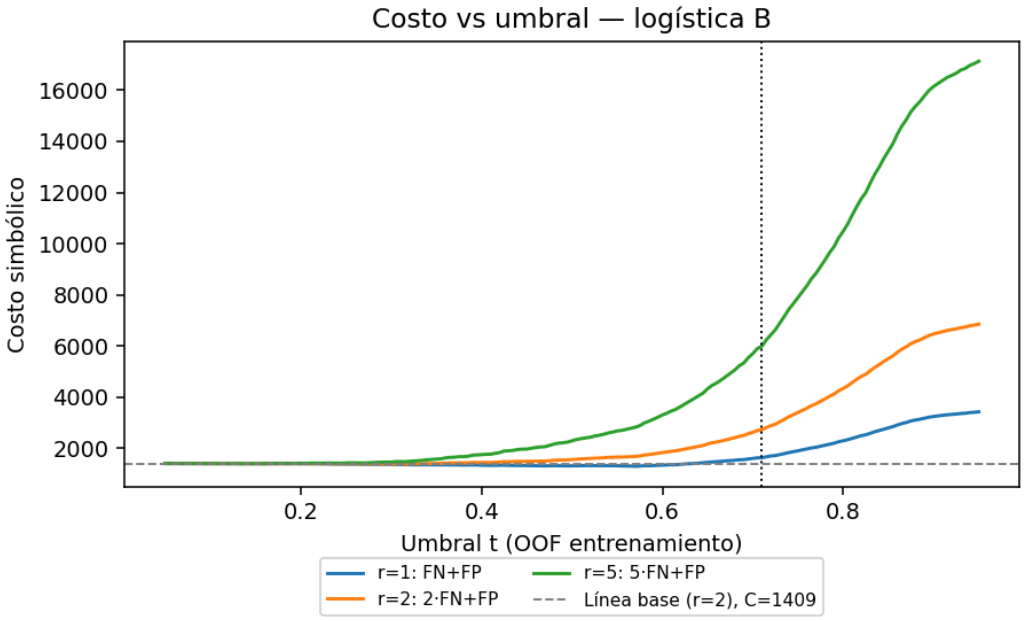


Figura 2: Costo simbólico frente al umbral en OOF ($r = 1$, $r = 2$, $r = 5$). Línea horizontal: línea base con $r = 2$.

En **prueba (solo lectura)** aplicamos los umbrales ya elegidos en OOF. La Tabla 7 resume FN, FP y recalls; no se buscó ningún corte óptimo en estos 1,215 clientes.

Tabla 7: Prueba (1,215 clientes): umbrales fijados en OOF, solo lectura.

Criterio (OOF)	t	**FN**	**FP**	**Rec. mora=1**	**Rec. mora=0**
Convención	0,50	50	265	0,942	0,247
Costo $r = 1$	0,57	82	229	0,905	0,349
Youden	0,71	268	129	0,689	0,634
Costo $r = 2$	0,27	4	334	0,995	0,051
Costo $r = 5$	0,14	0	352	1,000	0,000

Con $r = 2$ o $r = 5$ en la prueba casi todos quedan como mora (recall mora=0 ≈ 0). Youden y $r = 1$ reparten distinto los FN y FP; solo $r = 1$ fue competitivo en costo frente a la línea base en OOF.

9 Robustez: escenario C y sensibilidad en prueba (2.ª entrega)

Tabla 8: AUC en prueba por escenario (comparación ya realizada en 2.ª entrega).

Modelo	**A. Completo**	**B. Principal**	**C. sin score**
Regresión logística	0,734	0,722	0,709
LDA	0,730	0,719	0,707
KNN	0,721	0,714	0,702
Naive Bayes	0,692	0,685	0,677

Quitar `score` reduce poco el AUC. Mantenemos B pero documentamos la salvedad sobre el momento del `score`.

10 Interpretación del modelo final

Los coeficientes de la logística B (Figura 3) se leen junto con el umbral y el costo de errores. Las variables numéricas se escalan, así que cada OR es por cada desviación estándar. Son asociaciones en esta muestra, no causas.

- `score`: OR $\approx 0{,}75$; a mayor score, menor probabilidad modelada de mora.
- `nivel_ahorro`: OR $\approx 0{,}75$; `exp_sf`: OR $\approx 0{,}73$.
- `deuda_sf`: OR $\approx 1{,}15$; más deuda va con mayor OR de mora en el ajuste.

En categorías (one-hot, referencia implícita): zona Loreto OR $\approx 2{,}5$; Ucayali $\approx 2{,}4$; nivel universitario $\approx 0{,}62$ frente a la referencia de educación. Son patrones de esta base Kaggle, no reglas para todo el Perú.

El modelo ordena solicitudes para revisión manual; el comité fija umbral, costos y excepciones.

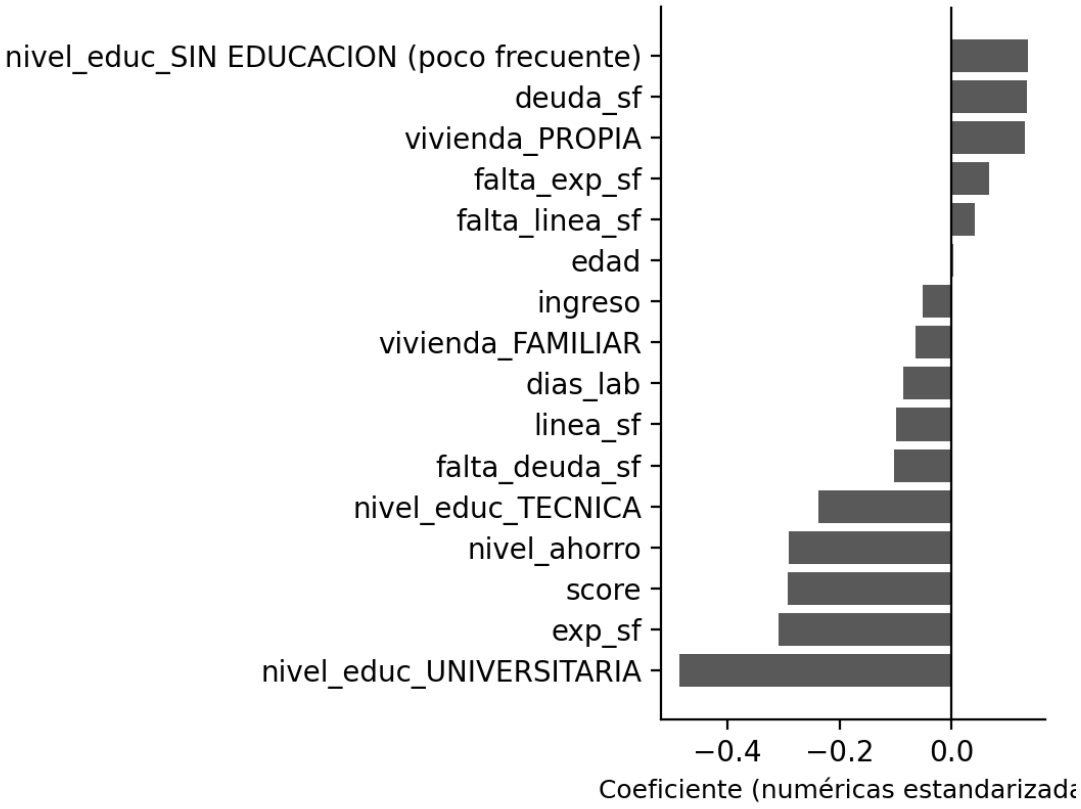


Figura 3: Coeficientes de la regresión logística, escenario B.

11 Despliegue básico (Streamlit)

La guía de la Fase 3 (§8.3) pide un despliegue básico. Usamos Streamlit con el mismo Python y `joblib` del proyecto. Es una demo local para la sustentación, no un sistema en producción.

En el paquete van `datos/database.csv`, `codigo/salidas_tercera/` (`pipeline_logistica_B.joblib`, `umbrales_recomendados.json`) y `codigo/app_streamlit/`. Instrucciones en `LEEME.md`. Serializado con scikit-learn 1.9.1 e imbalanced-learn 0.14.2.

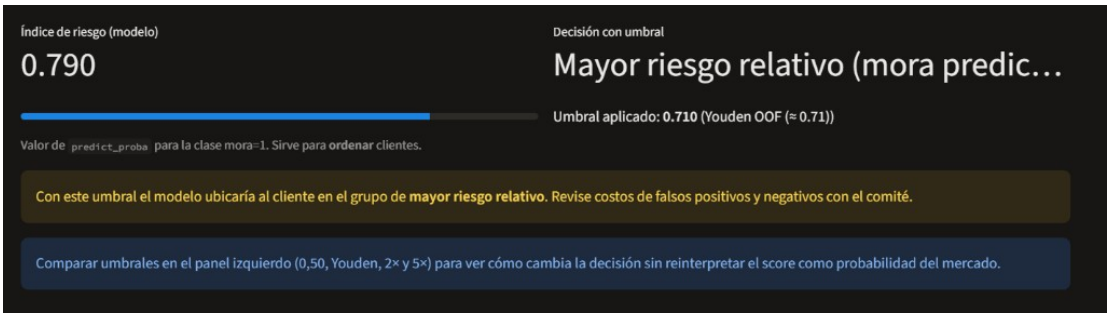


Figura 4: Captura **local** de la demo Streamlit: perfil ingresado manualmente, umbral Youden OOF ($t \approx 0{,}71$), resultado calculado (índice de riesgo 0,790; decisión según ese corte).

12 Conclusiones y condiciones de uso

- Con información previamente disponible y escenario B, la logística separa mejor que la línea base (AUC ≈0,72, discriminación moderada).
- El umbral condiciona la decisión práctica. Con $r = 5$ (y en $r = 2$) el corte óptimo en OOF casi no mejora rechazar a todos en costo; con $r = 1$ el costo simbólico baja ≈7,6%. Youden cambia el balance de FN y FP, pero no baja C frente a la línea base. El score sirve para priorizar por riesgo relativo.
- Usamos el score para priorizar en muestras similares solo si el comité acepta las limitaciones (temporalidad, prevalencia, `score`) y no interpreta `predict_proba` como probabilidad de mora en Perú ni reutiliza la misma prueba para nuevas decisiones de modelo.

Proyección (Machine Learning II). Calibración de probabilidades, validación temporal con fechas, cost-sensitive learning con costos reales del banco y modelos más flexibles con control de sobreajuste.

Declaración de uso de inteligencia artificial

Juan Angel Triana usó **Claude (Sonnet 5)** vía Cursor para apoyo en código Python, notebook, aplicación Streamlit, tablas y borradores del informe. **Isabella Pensamiento** usó **Claude (Sonnet 5)** para revisar el informe, preparar diapositivas y guion de sustentación. Herramientas: Cursor IDE; `Python 3.12`; `scikit-learn 1.9.1`; `imbalanced-learn 0.14.2`; Streamlit ≥1.28. El equipo revisó, ajustó y es responsable del contenido técnico y de las decisiones del proyecto.

Referencias

1. Attota, D. C., & Yarmohammadtoosky, S. (2024). *Optimizing Fintech Marketing: A Comparative Study of Logistic Regression and XGBoost*. Kennesaw State University. arXiv:2412.16333.

2. Calderón Baldeón, L. H. (2021). *BankDefaultAnalysis: Morosidad del Sistema Financiero* [Conjunto de datos]. Kaggle. `https://doi.org/10.34740/KAGGLE/DSV/2528417`

3. Superintendencia de Banca, Seguros y AFP del Perú (SBS). (2021). *Clasificación de riesgo crediticio y estadísticas de morosidad del sistema financiero peruano*. `https://www.sbs.gob.pe`

4. Anthropic. (2026). Claude (Sonnet 5) [Modelo de lenguaje de gran escala]. `https://claude.ai`