Guion oral: presentación al comité de riesgo

Machine Learning I · Entrega final · Isabella Pensamiento y Juan Angel Triana

Duración pensada: unos 13 minutos más preguntas. Si les dan menos tiempo, se recortan primero la diapositiva 8 (señales del modelo) y la 4 (AUC), que se pueden dejar en una frase cada una.

Regla para los dos: hablen como si le explicaran a alguien del banco que no sabe de modelos. Nada de "logit", "OOF" ni "hiperparámetro" sin traducir.

Regla de reparto: cada diapositiva la dice una sola persona.

Quién dice qué

Diapositiva	Tema	Habla	Tiempo
1	La pregunta del comité	Isabella	0:45
2	Imagina 100 solicitudes	Isabella	1:00
3	El artículo y los datos	Juan	1:15
4	Qué tan bien separa a buenos y malos pagadores	Juan	1:00
5	Las dos maneras de equivocarse	Isabella	1:00
6	El corte decide a quién aprobamos	Isabella	1:15
7	Cuánto ganamos y con qué corte	Juan	1:45
8	Qué señales mira el modelo	Isabella	1:00
9	Lo que todavía no sabemos	Juan	1:15
10	Demostración	Juan	2:00
11	Cuándo lo recomendamos y conclusión	Isabella	1:00

Isabella habla unos 6:00 y Juan unos 7:15. Las dos personas tienen que poder responder cualquier pregunta; el reparto es solo para la exposición.

Texto sugerido, diapositiva por diapositiva

1. La pregunta (Isabella)

"Buenos días. Nos hicimos la pregunta que le importa a un comité de riesgo: ¿podemos usar la información de un solicitante para priorizar clientes por riesgo sin rechazar de más a los buenos pagadores? Vamos a mostrarles qué se puede responder con los datos que tenemos, y cuánto depende esa respuesta del corte que ustedes elijan."

2. Imagina 100 solicitudes (Isabella)

"Imaginen 100 solicitudes de crédito como las de nuestra base. 71 están marcadas como morosas y 29 son buenos pagadores. Con eso, la regla más simple es rechazar a casi todos. No distingue a nadie y deja fuera a los 29 que sí pagan. Esa es la regla contra la que medimos el modelo.

El modelo no aprueba ni rechaza. Entrega un índice que ordena a los clientes de menor a mayor riesgo, y ustedes deciden dónde ponen el corte. Y ustedes conocen los dos costos: rechazar a un buen pagador es una venta perdida; aprobar a un moroso es dinero que no vuelve."

3. El artículo y los datos (Juan)

"El artículo es de Attota y Yarmohammadtoosky, de 2024. Trabajan con una fintech de unos 988 mil clientes y 541 variables. Nosotros reproducimos uno de sus modelos, el que predice quién podría caer en mora, con regresión logística. No reproducimos la escala: no usamos XGBoost ni las 541 variables.

Nuestra base es peruana. Quedan 6.074 clientes únicos después de quitar los duplicados. Entrenamos con 80 % y probamos con el otro 20 %. Dejamos afuera dos datos, atraso y clasificación SBS, porque podrían ser posteriores a la mora y harían trampa.

Con nuestros datos el resultado es menor que el del artículo. Tenemos posibles razones, como la muestra o la falta de diccionario, pero no las comprobamos."

4. Qué tan bien separa (Juan)

"El AUC mide qué tan bien el modelo ordena a los clientes. Tenemos 0,72. Eso quiere decir que si tomamos un moroso y un buen pagador al azar, en unas 72 de cada 100 parejas el modelo le da más riesgo al moroso. El azar daría 50. Es una capacidad moderada. No es un 72 % de aciertos."

5. Las dos maneras de equivocarse (Isabella)

"Antes de hablar del corte, hay que ponerle nombre a lo que está en juego. Un modelo se equivoca de dos maneras.

La primera es aprobar a un moroso. En términos técnicos, un falso negativo. El banco presta y no recupera: pierde el capital y los intereses, y paga la cobranza.

La segunda es rechazar a un buen pagador, un falso positivo. El banco pierde los intereses y las comisiones de ese cliente, y quizá al cliente para siempre.

Normalmente duele más la primera, porque se pierde el capital y no solo la ganancia. Pero cuánto más depende de cada banco, y nosotros no tenemos esos costos. Por eso probamos tres casos: que el moroso cueste lo mismo, el doble o cinco veces más."

6. El corte (Isabella)

"Este es el centro del problema. Con el corte habitual de 0,50, el modelo detecta casi todos los morosos, pero solo aprobamos a 25 de cada 100 buenos pagadores. Con 0,71 aprobamos 63 de cada 100 buenos, pero aprobamos por error a 31 morosos de cada 100. No hay un corte gratis: subirlo cambia a quién le fallamos."

7. Cuánto ganamos y con qué corte (Juan)

"¿Qué ganamos frente a rechazar a todos, y con qué corte? Depende de cuánto cuesta cada error.

Si el moroso cuesta lo mismo que un buen pagador rechazado, el mejor corte es cerca de 0,57. Baja el costo 7,6 % y aprueba 35 de cada 100 buenos pagadores.

Si el moroso cuesta el doble, el mejor corte es 0,27. Pero ya casi no aprueba a nadie, solo 3 de cada 100 buenos pagadores, y la ganancia es de 1,2 %.

Si cuesta cinco veces más, la mejor regla es rechazar a todos: la ganancia es 0,4 %. Con los clientes de prueba pasa lo mismo.

Una aclaración: el corte de equilibrio, 0,71, reparte mejor los errores entre los dos grupos, pero no ahorra frente a rechazar a todos en ninguno de los tres casos. En resumen, este modelo sirve cuando los dos errores cuestan parecido."

8. Qué señales mira el modelo (Isabella)

"En lenguaje de banco: más score, más ahorro y más experiencia en el sistema financiero se asocian con menos riesgo, entre 25 y 27 % menos. Más deuda se asocia con más riesgo, cerca de 15 %. Eso es por cada subida típica de la señal, con las demás iguales. Son asociaciones en esta muestra, no causas. El modelo ordena la cola de revisión; no reemplaza la política de cupos."

9. Lo que todavía no sabemos (Juan)

"Esto no lo escondemos, porque es lo que más pesa en la lectura.

La principal: no sabemos cuándo ocurrió la mora. No tenemos fechas ni diccionario, así que no podemos demostrar que estamos prediciendo mora futura.

Segunda: la muestra no es el mercado. Aquí 71 de cada 100 son morosos y en el Perú está entre 4 y 11. Por eso el índice ordena, pero no es una probabilidad real.

Tercera: el score podría haberse actualizado después de la mora. Probamos sin él y el resultado casi no cambia, de 0,72 a 0,71.

Cuarta: ya miramos la prueba una vez, en la entrega anterior. Ahora no la usamos para elegir nada.

Y quinta: los costos son de ejemplo. El banco tendría que poner los suyos y repetir el cálculo."

10. Demostración (Juan)

Los 11 datos que pide la aplicación

Aviso: la base no trae diccionario. Estas descripciones salen de los nombres de las columnas; no son definiciones oficiales ni sabemos las unidades.

Dato	Qué es	Rango en la base
Edad	Edad del solicitante	20 a 85
Días laborando	Cuánto tiempo lleva trabajando	2.956 a 20.700
Experiencia en el sistema financiero	Cuánta experiencia tiene con entidades financieras	0 a 130
Nivel de ahorro	Nivel de ahorro del cliente	0 a 12
Ingreso	Ingreso del solicitante	124 a 30.000
Línea en el sistema financiero	Línea de crédito que ya tiene	0 a 121.543
Deuda en el sistema financiero	Deuda que ya tiene	0 a 57.094
Score crediticio	Puntaje de crédito	134 a 266
Vivienda	Alquilada, familiar o propia	
Zona	Dónde vive (Lima, Arequipa, Piura, etc.)	
Nivel educativo	Sin educación, secundaria, técnica o universitaria	

Solicitante de ejemplo. La aplicación ya trae precargados los valores típicos de la base: edad 34, días laborando 4.874, experiencia 19, ahorro 12, ingreso 2.225,8, línea 3.725, deuda 2.297,47, score 196, vivienda alquilada, zona Lima, nivel educativo secundaria. Con esos valores el índice da 0,790, igual que la captura del informe.

Guion de la demo

1. Abrir la app. Juan: "Esta es una aplicación local. Entra un solicitante y sale un índice de riesgo."
2. Dejar los valores típicos y pulsar "Calcular riesgo" con el corte de equilibrio (0,71). Debe dar 0,790, "mayor riesgo". Decir: "Un cliente típico de la base queda del lado de mayor riesgo."
3. Cambiar el score a 230 y calcular de nuevo. Debe dar cerca de 0,693. Con el corte de 0,71 ya no queda marcado. Decir: "Un score más alto baja el índice."
4. Cambiar el corte a "Costo 1×" (0,57) y calcular con el mismo cliente. Ahora sí queda marcado. Decir: "El mismo cliente cae de un lado o del otro según el corte que elija el comité."
5. Cambiar a "Costo 2×". Mostrar el aviso. Decir: "La aplicación avisa que con este corte casi todos quedan marcados, es igual a rechazar a todos."
6. Si preguntan por la pestaña "Ejemplo desde la base": son clientes que se usaron para entrenar, solo ilustración.

7. Tener la captura de pantalla de respaldo por si falla el equipo.

Los valores de los pasos 2 y 3 los calculé con el modelo guardado fuera de la app. Verifíquenlos en la app antes de presentar.

11. Cuándo lo recomendamos y conclusión (Isabella)

"Lo recomendamos como apoyo para ordenar y priorizar solicitudes, con un analista que decide, cuando dejar pasar a un moroso cuesta parecido a rechazar a un buen pagador, con un corte cerca de 0,57. No lo recomendamos como decisión automática si el moroso cuesta el doble o más, ni para dar probabilidades reales de mora, ni en otra población sin volver a validarlo.

Nuestra conclusión: sirve para priorizar solicitudes cuando los dos errores cuestan parecido. Antes de usarlo en serio faltan cuatro cosas: calibrar con una muestra representativa, validar con fechas, usar los costos reales del banco y probar modelos más flexibles. Eso es lo que seguiría en Machine Learning II. Gracias."

Traducción de términos para hablar con el comité

Término técnico	Cómo decirlo
Umbral o corte	El puntaje desde el cual revisamos o rechazamos
Falso negativo	Aprobar a un moroso
Falso positivo	Rechazar a un buen pagador
Recall de mora	De cada 100 morosos, cuántos detectamos
Especificidad	De cada 100 buenos pagadores, cuántos aprobamos
AUC	Qué tan bien el modelo ordena a los clientes por riesgo
Línea base	La regla simple de rechazar a casi todos
Costo simbólico, r	Cuántas veces más cuesta aprobar a un moroso que rechazar a un buen pagador
Odds	Probabilidades relativas de mora
Validación cruzada	Probar el modelo varias veces con partes distintas del entrenamiento

---

Preguntas probables y respuestas cortas

1. ¿Qué cuesta más, aprobar a un moroso o rechazar a un buen pagador? Suele costar más aprobar a un moroso, porque se pierde el capital, los intereses y se paga cobranza. Rechazar a un buen pagador pierde los ingresos de ese cliente. Cuánto más cuesta lo primero depende de cada banco. No tenemos esos costos, por eso probamos que cueste lo mismo, el doble o cinco veces más.

2. ¿Por qué regresión logística y no un modelo más complejo? Comparamos logística, LDA, KNN y Naive Bayes con validación cruzada. Logística, LDA y KNN quedaron casi iguales (0,698, 0,699 y 0,689), con diferencias menores que la variación entre pruebas. Elegimos la logística porque se puede explicar. No agregamos más modelos para no seguir mirando la misma prueba.

3. ¿Qué significa un AUC de 0,72? Que el modelo ordena mejor que el azar, pero está lejos de separar perfecto. En unas 72 de cada 100 parejas moroso–buen pagador, el moroso recibe más riesgo. No es 72 % de aciertos.

4. ¿Qué ganan frente a rechazar a todos? Solo cuando los dos errores cuestan parecido: 7,6 % menos de costo. Si el moroso cuesta el doble, 1,2 %; con cinco veces, casi nada.

5. ¿Por qué con costo 2× o 5× el modelo no sirve? Con ese costo, el mejor corte termina marcando casi a todos, que es igual a rechazar a todos. Una razón probable es que 71 % de la muestra es mora: rechazar a todos ya cuesta poco. Es una explicación posible, no la probamos.

6. ¿Esto funcionaría en el Perú real? No lo sabemos. Nuestra muestra tiene 71 % de morosos y el país 4 % a 11 %. Haría falta una muestra representativa y calibrar el modelo. Los cortes y los costos cambiarían.

7. ¿Cuál es la probabilidad de que este cliente caiga en mora? No se la podemos dar. El índice sirve para ordenar clientes dentro de una población parecida a la muestra. Para dar probabilidades reales habría que calibrar.

8. ¿Cómo saben que no hay fuga de información? Sacamos atraso y clasificación SBS porque pueden ser posteriores a la mora. Hicimos pruebas: sin filas repetidas entre entrenamiento y prueba, y con etiquetas mezcladas el AUC cae a cerca de 0,49. Con el score no podemos estar seguros, por eso lo probamos sin él: 0,72 baja a 0,71.

9. ¿Qué pasó con el conjunto de prueba? Lo usamos en la segunda entrega para comparar. En esta fase no lo usamos para elegir modelo ni cortes. Los cortes salen del entrenamiento y la prueba solo se lee.

10. ¿Por qué incluyen la edad si el artículo la excluyó? Su efecto en el modelo es casi cero. El artículo la dejó fuera por criterio de equidad. Es una decisión que el comité podría tomar. No probamos el modelo sin edad.

11. ¿Qué pasa si falta un dato del cliente? El modelo sabe manejar datos faltantes: usa la mediana y marca que faltaba. La aplicación todavía no deja un campo vacío. Es una mejora pendiente.

12. ¿Probaron balanceo de clases? Probamos cinco estrategias, incluida SMOTE. En estos datos casi no cambiaron el AUC. No generalizamos eso a otros casos.

13. ¿Qué es el corte de equilibrio (Youden)? El corte que mejor equilibra detectar morosos y aprobar buenos pagadores. En nuestro caso es 0,71. Sirve para repartir los errores, no para ahorrar costo.

14. ¿Quién decide el corte? El comité, según cuánto le cueste cada error. El modelo no lo fija solo.

15. ¿Por qué el score podría ser un problema? Si el score se actualiza después de que el cliente cae en mora, estaría usando información del futuro. No tenemos fechas para saberlo. Por eso lo mantenemos con la salvedad y mostramos el resultado sin él.

Ensayo con Juan (tres rondas)

1. **Ronda de lectura:** cada uno lee su texto en voz alta con la diapositiva. Cronometren. Ajusten palabras que se les atoren.
2. **Ronda completa con demo:** de la diapositiva 1 a la 11, con la app abierta y el solicitante de ejemplo. Alguien más cronometra.
3. **Ronda de preguntas:** uno hace de comité y lanza cinco preguntas de la lista sin avisar cuáles. Cambian de rol.

Antes de entrar: probar la app en el computador donde van a presentar, con las versiones de librerías del README, y tener lista la captura de respaldo.