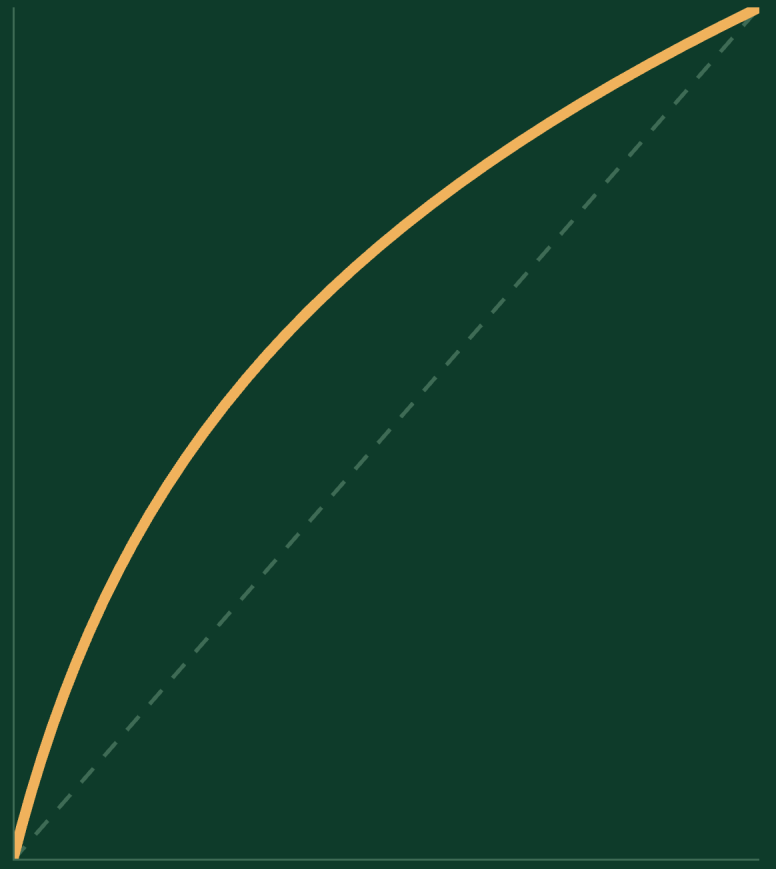
SEGUNDA ENTREGA · PROYECTO INTEGRADOR · MACHINE LEARNING I

Riesgo de incumplimiento crediticio

Regresión logística en contexto latinoamericano



Isabella Pensamiento · Juan Angel Triana

Profesora: Juliana De Mier

Universidad Externado de Colombia

Ciencia de Datos · Octubre 2026

01 · EL PROBLEMA

Predecimos quién queda marcado como moroso

La etiqueta

mora = 1 · cliente marcado como moroso

mora = 0 · pagador al día

Crédito de consumo en Perú · BankDefaultAnalysis (Kaggle, 2021)

Los datos

8.399 registros

−2.325 duplicados exactos

6.074 clientes únicos

71 %

de los clientes de la muestra está en mora

En el Perú la morosidad real es 4–11 %: el modelo ordena clientes, no mide prevalencia

Ajustes tras la entrega 1: Momento de predicción y fuga · Pipeline reproducible · LDA, KNN y Naive Bayes

02 · AUDITORÍA DE FUGA

Auditamos la fuga con tres escenarios

Pregunta guía: **¿qué sabe el banco antes de conceder el crédito?**

A · COMPLETO

13 variables

Incluye **atraso** y **clasif_sbs**: describen el pago y podrían medirse después de la mora

B · PRINCIPAL Elegido

11 variables

Sin atraso ni clasif_sbs: solo lo que el banco conoce al evaluar al cliente

C · CONSERVADOR

10 variables

B sin **score**, por si el score se actualiza después de un atraso

+0,007 a +0,012 Es lo que sube el AUC al incluir las sospechosas: menos que la variación de la CV. **Nos quedamos con B.**

03 · FLUJO SIN FUGA

El preprocesamiento vive dentro del pipeline



Partición

80 / 20

Estratificada por mora · semilla 42
4.859 entrenamiento · 1.215 prueba

Comprobamos en el notebook

- 0 filas compartidas entre entrenamiento y prueba
- La mediana sale solo del entrenamiento
- Con etiquetas mezcladas el AUC cae a ≈ 0,49

Balancear no mejoró la discriminación

Regresión logística · escenario B · validación cruzada, solo en entrenamiento

Opción	AUC	PR-AUC	Recall mora=0
Sin balancear	0,698	0,835	0,236
Peso de clases	0,699	0,836	0,612
Submuestreo	0,695	0,834	0,614
Sobremuestreo	0,698	0,836	0,608
SMOTE	0,695	0,834	0,616

Línea base: siempre predice mora

0,500
AUC

0,710
Precision mora=1

1,000
Recall mora=1

0,000
Recall mora=0

Números altos, modelo inútil: rechaza a todos los buenos pagadores

El AUC no cambia → entrenamos sin balancear. El balanceo solo mueve el corte; el peso de clases queda como alternativa para los tipos de error.

Entrenamos cuatro modelos del curso

Principal

Regresión logística

Permite leer odds ratio y comparar con el artículo

Sin penalización

Comparador lineal

LDA

Frontera lineal entre clases con supuestos gaussianos

Sin hiperparámetros

No paramétrico

KNN

Busca clientes parecidos, sin forma fija

k = 151, elegido por CV

Contraste

Naive Bayes

Supone independencia; medimos cuánto cuesta

Correlaciones de hasta 0,55

Fuera de alcance: XGBoost y la limpieza de 541 variables del artículo

Entrega final: QDA, Ridge y Lasso

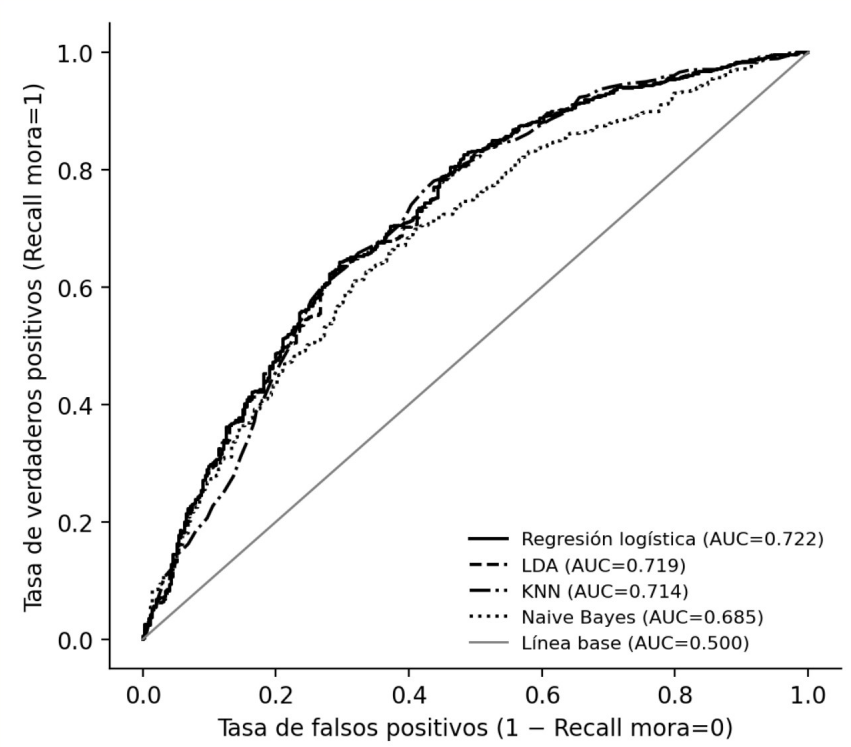
06 · VALIDACIÓN CRUZADA

En validación cruzada, logística y LDA empatan

Modelo	ROC-AUC medio · 5 folds · eje de 0,50 (azar) a 0,75	Media	± desv.	PR-AUC
Regresión logística		0,698	± 0,017	0,835
LDA		0,699	± 0,017	0,835
KNN (k = 151)		0,689	± 0,015	0,827
Naive Bayes		0,657	± 0,012	0,806

Las diferencias son menores que la desviación entre folds: no coronamos un ganador. Naive Bayes queda atrás, como esperábamos.

En prueba pasamos de 0,50 a 0,72 de AUC



Modelo	AUC	PR-AUC
Línea base	0,500	0,710
Regresión logística	0,722	0,840
LDA	0,719	0,838
KNN	0,714	0,830
Naive Bayes	0,685	0,828

IC 95 % bootstrap · AUC de la logística

0,689 – 0,751

Se solapa con LDA y KNN

1.215 clientes de prueba, evaluados una sola vez con los modelos ya elegidos

08 · UMBRAL DE DECISIÓN

El corte mueve los errores, no el AUC

J = sensibilidad + especificidad − 1 **≈ 0,71** Estimado con predicciones out-of-fold del entrenamiento, nunca con la prueba

Regresión logística en prueba	Umbral 0,5	Youden 0,71
Morosos que se escapan (FN)	50	268
Buenos pagadores reconocidos (recall mora=0)	24,7 %	63,4 %
Morosos detectados (recall mora=1)	94,2 %	68,9 %
Precision al marcar mora	0,754	0,822

El corte correcto depende del costo de cada error para el banco, y esta base no trae esos costos.

09 · SENSIBILIDAD A LAS VARIABLES

Quitar atraso y clasif_sbs cuesta muy poco

AUC en el conjunto de prueba según el escenario de variables

Escenario	Logística	LDA	KNN	Naive Bayes
A · Completo (13)	0,734	0,730	0,721	0,692
B · Principal (11)	0,722	0,719	0,714	0,685
C · Sin score (10)	0,709	0,707	0,702	0,677

+0,007 a +0,012

Ganancia de A sobre B: menor que la variación de la CV

−0,008 a −0,013

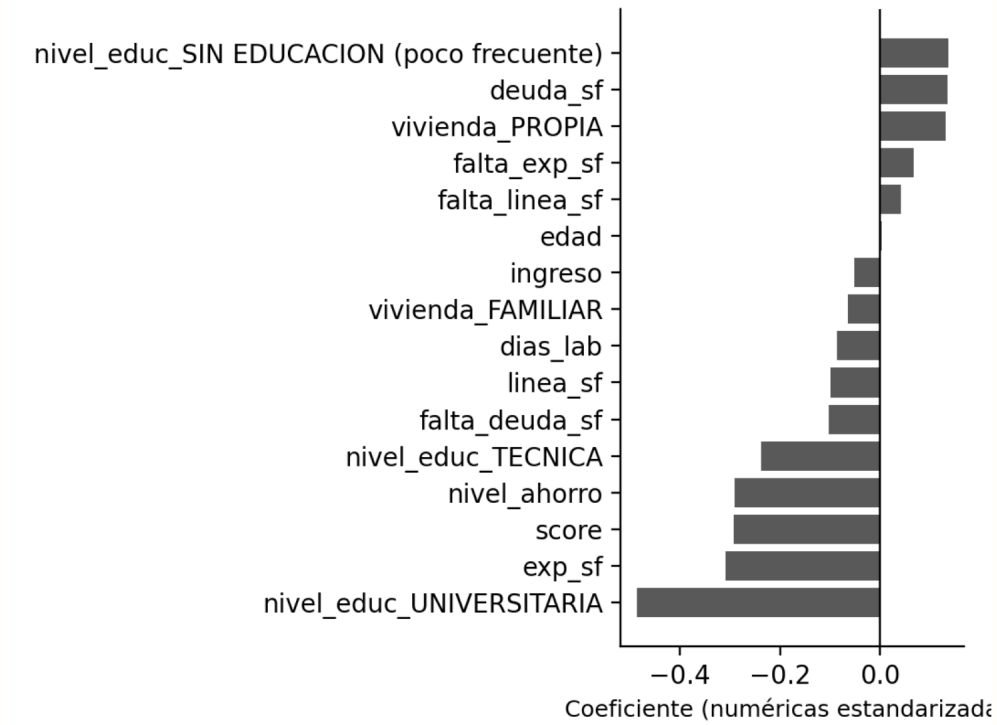
Pérdida al quitar el score: sí aporta, con salvedad

Escenario B

Poco poder perdido y sin variables medidas después de la mora

10 · INTERPRETACIÓN PRELIMINAR

Lo que el modelo asocia con la mora



Van con menos mora

Educación universitaria	−0,49
Experiencia en el sistema	−0,31
Score	−0,29
Nivel de ahorro	−0,29

Van con algo más de mora

Deuda en el sistema	+0,14
Vivienda propia vs. alquilada	+0,13

Asociación, no causa · supuesto: relación lineal con el **logit**, no con la probabilidad

11 · LIMITACIONES Y PRÓXIMOS PASOS

Lo que todavía no podemos afirmar

Sin diccionario de datos
La definición de mora y el momento de cada variable son supuestos

Sin fechas ni identificador de cliente
No hay validación temporal ni certeza de que los duplicados sean la misma persona

71 % de mora en la muestra
Las probabilidades ordenan clientes; no miden riesgo poblacional

PRÓXIMOS PASOS · ENTREGA FINAL

QDA, Ridge y Lasso · matriz de costos FN / FP para fijar el umbral de operación

GRACIAS

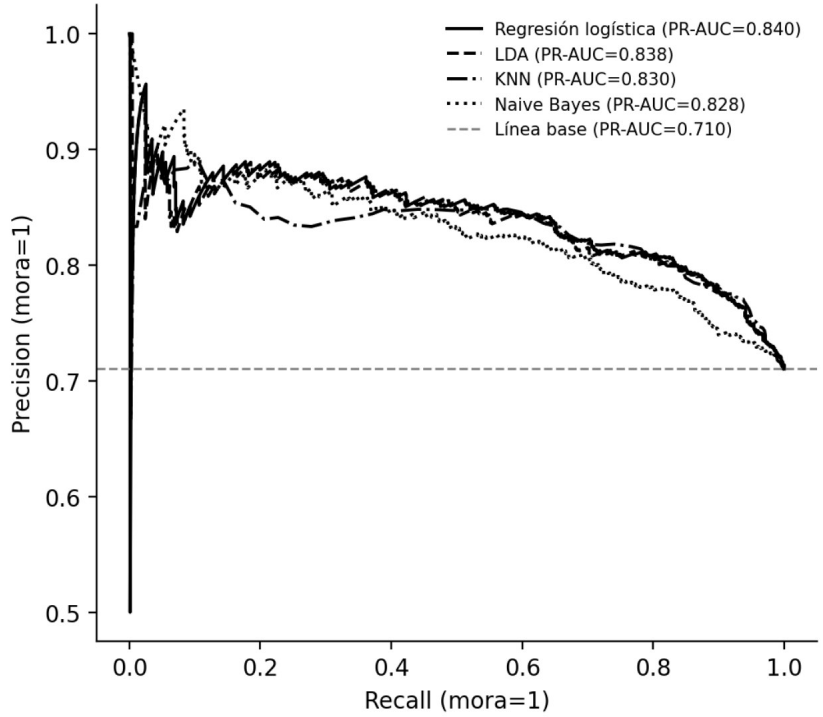
¿Preguntas?

Isabella Pensamiento
Juan Angel Triana

Notebook e informe de la segunda entrega disponibles para revisión

RESPALDO · SOLO SI PREGUNTAN

Curva precision–recall y matriz de confusión



Regresión logística · umbral 0,5 · 1.215 clientes de prueba

	Predice sin mora	Predice mora
Real: sin mora	87 VN	265 FP
Real: con mora	50 FN	813 VP

En la curva PR, la línea punteada es la prevalencia de mora (0,71): es lo que logra la línea base