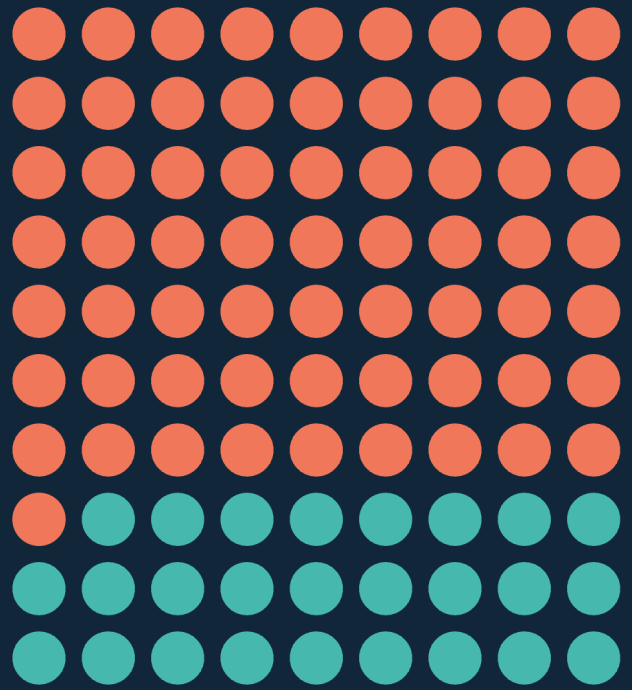
PROPUESTA PARA EL COMITÉ DE RIESGO

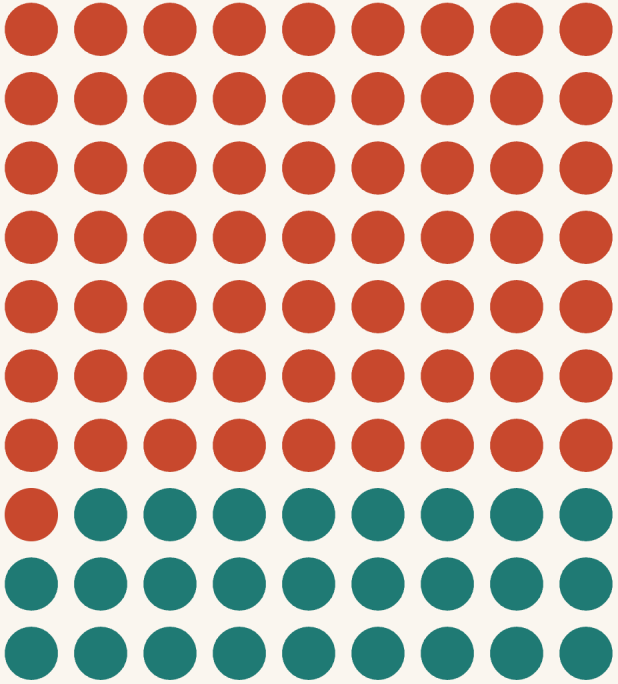
¿Podemos priorizar solicitantes por riesgo sin rechazar de más a buenos pagadores?



Isabella Pensamiento · Juan Angel Triana

Machine Learning I · Universidad Externado de Colombia · Noviembre de 2026

Imagina 100 solicitudes de crédito



- 71 están marcados como morosos
- 29 son buenos pagadores

La regla más simple es rechazar a casi todos. No distingue a nadie y deja fuera a los 29 que sí pagan.

El modelo propone otra cosa: ordenar las solicitudes de menor a mayor riesgo. El banco decide dónde pone el corte.

Rechazar a un buen pagador es una venta perdida. Aprobar a un moroso es dinero que no vuelve.

De dónde partimos

EL ARTÍCULO (2024)

988.000

clientes de una fintech y 541 variables

Entre sus modelos hay uno que predice quién podría caer en mora. Ese es el que reproducimos, con regresión logística.

No reproducimos la escala: sin XGBoost ni las 541 variables.

NUESTRA BASE PERUANA (2021)

6.074

clientes únicos y 11 variables

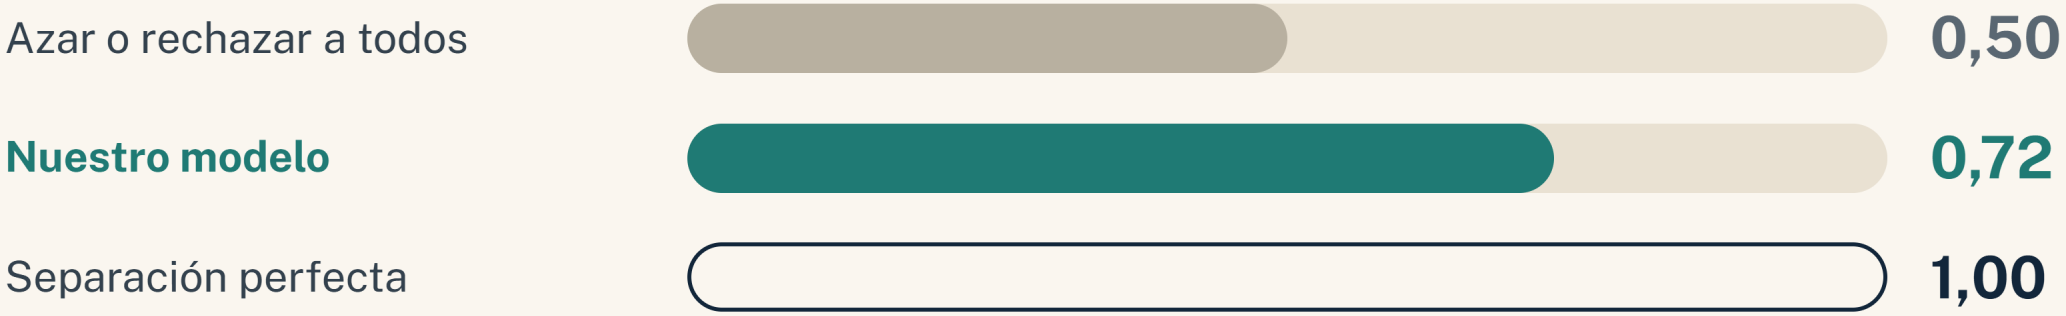
Entrenamos con 80 % de los clientes y probamos con el otro 20 %.

Dejamos fuera dos datos, atraso y clasificación SBS, porque podrían ser posteriores a la mora.

Nuestro resultado es menor que el del artículo. Hay razones posibles, como la muestra o la falta de diccionario de datos, pero no las comprobamos.

Fuentes: Attota y Yarmohammadtoosky (2024), arXiv:2412.16333; Calderón Baldeón (2021), Kaggle.

¿Qué tan bien separa a buenos y malos pagadores?



Si tomamos al azar un moroso y un buen pagador, en unas 72 de cada 100 parejas el modelo le asigna más riesgo al moroso. El azar daría 50.

Ordena mejor que lanzar una moneda, pero está lejos de ser perfecto.

Medida: AUC en 1.215 clientes de prueba. No equivale a un 72 % de aciertos.

El modelo se puede equivocar de dos maneras

ERROR 1 · FALSO NEGATIVO

Aprobamos a un moroso

El banco presta y no recupera: pierde el capital y los intereses, y además paga la cobranza.

ERROR 2 · FALSO POSITIVO

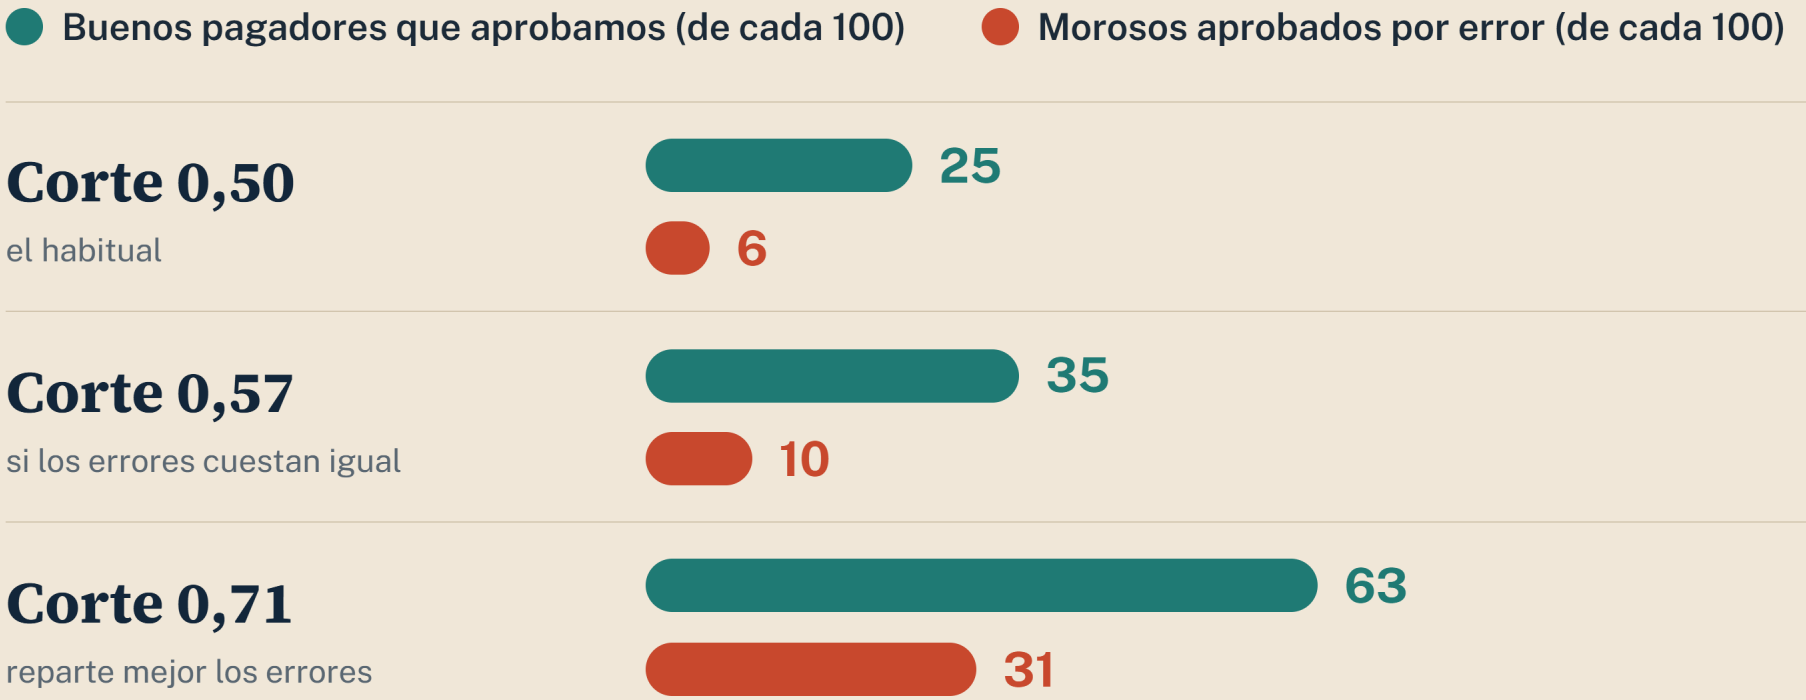
Rechazamos a un buen pagador

El banco pierde los intereses y las comisiones de ese cliente, y quizá al cliente para siempre.

Suele doler más el primero, porque se pierde el capital y no solo la ganancia. Cuánto más, depende de cada banco.

No tenemos los costos reales. Por eso probamos tres casos: que el moroso cueste lo mismo, el doble o cinco veces más.

El corte decide a quién aprobamos



Subir el corte aprueba más buenos pagadores, pero deja pasar más morosos.

Resultados con los 1.215 clientes de prueba. Los cortes se fijaron antes, con el entrenamiento.

¿Cuánto ganamos y con qué corte?

Si un moroso cuesta lo mismo



7,6 % menos

Corte 0,57: aprueba 35 de 100 buenos pagadores y 11 de 100 morosos.

Si cuesta el doble



1,2 % menos

Corte 0,27: aprueba 3 de 100 buenos pagadores y menos de 1 de 100 morosos. Casi igual que rechazar a todos.

Si cuesta cinco veces más



0,4 % menos

Corte 0,14: no aprueba a casi nadie. Es rechazar a todos.

Este modelo sirve cuando los dos errores cuestan parecido.

El corte de equilibrio (0,71) reparte mejor los errores entre los dos grupos, pero no ahorra frente a rechazar a todos en ninguno de los tres casos.

Costo en unidades de ejemplo: cada buen pagador rechazado cuenta 1 y cada moroso aprobado cuenta 1, 2 o 5. Cortes elegidos con el entrenamiento. Con los clientes de prueba el patrón se repite.

¿Qué señales mira el modelo?

Más score crediticio	↓	Menos riesgo, cerca de 25 %
Más ahorro	↓	Menos riesgo, cerca de 25 %
Más experiencia en el sistema financiero	↓	Menos riesgo, cerca de 27 %
Más deuda en el sistema financiero	↑	Más riesgo, cerca de 15 %

Lectura aproximada, con las demás señales iguales. Son asociaciones en esta muestra, no causas. La zona y el nivel educativo también mueven el índice.

El modelo ordena la cola de revisión. No reemplaza la política de cupos.

Lo que todavía no sabemos

1	**No sabemos cuándo ocurrió la mora**	Sin fechas ni diccionario no podemos asegurar que se predice mora futura. Es la limitación principal.
2	**La muestra no es el mercado**	Aquí 71 de cada 100 son morosos; en el Perú, entre 4 y 11. El índice ordena, no da probabilidades reales.
3	**Un dato podría llegar tarde**	El score podría actualizarse después de la mora. Sin él, el resultado casi no cambia: de 0,72 a 0,71.
4	**Ya miramos la prueba una vez**	La usamos en la entrega anterior. En esta fase no sirvió para elegir nada.
5	**Los costos son de ejemplo**	El banco tendría que poner los suyos y repetir el cálculo.

Así lo usaría un analista del banco

1 Ingresa los 11 datos de un solicitante.

2 Lee el índice de riesgo y la decisión con el corte elegido.

3 Cambia el corte y ve cómo cambia la decisión para el mismo cliente.

Con el corte de 2× o 5× la aplicación avisa que marca a casi todos. Los clientes de la pestaña «Ejemplo desde la base» son solo una ilustración: se usaron para entrenar.

Demostración en vivo. Aplicación local en Streamlit, con el mismo modelo guardado y las mismas 11 variables.

Cuándo recomendamos usar el modelo

✓ Sí, para

- Ordenar la cola de revisión de solicitudes.
- Cuando dejar pasar a un moroso cuesta parecido a rechazar a un buen pagador.
- Con un corte cercano a 0,57 y un analista que decide.

⚠ No, para

- Aprobar o rechazar solo con el modelo si un moroso cuesta el doble o más.
- Decir que un cliente tiene tal porcentaje de probabilidad de mora.
- Usarlo en otra población sin volver a validarlo.

NUESTRA CONCLUSIÓN

Sirve para priorizar solicitudes cuando los dos errores cuestan parecido. Antes de usarlo en serio faltan cuatro cosas.

Calibrar con una muestra representativa, validar con fechas, usar los costos reales del banco y probar modelos más flexibles. Eso es lo que seguiría en Machine Learning II.